可视化实践过程记录

0. 前期准备

0. 资料来源

论文：https://arxiv.org/abs/2503.01141

数据采集代码：https://github.com/Compressed-CoT/compressed-cot

硅基流动邀请链接：https://cloud.siliconflow.cn/i/erPHzyKP

vega-lite：https://istarrysummer.github.io/trace-visualization/?v=b972beb

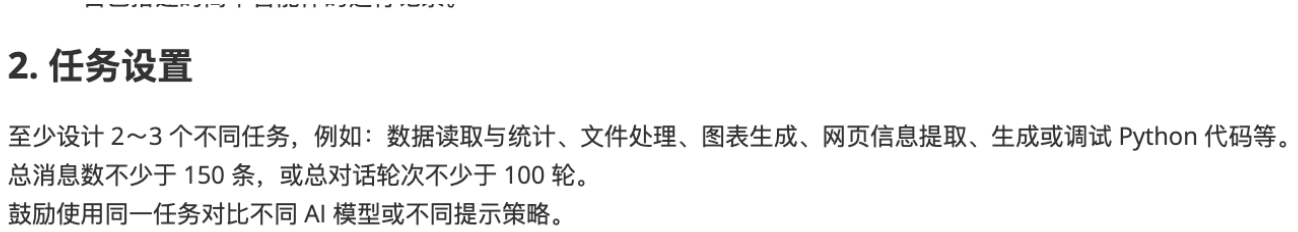
三份 apikey：
sk-ukavqouwjyvrgcsfiwuectsmmzvkszcofjibxgrqjtesgsmu

sk-usnaxbeidjurpbyxsogrmkoxfdzvvgubccrvfkenwbzuhrxh

sk-tpheumsdmuuscjgfstycudbemoahzcrvcaijudmbscuuwyuo

1.实践要求

1. 我们有三个不同类型的数学题集，也许可以算做三个任务？（？？？？数学，图表生成，代码）推荐模型



2. 任务设置

至少设计 2~3 个不同任务，例如：数据读取与统计、文件处理、图表生成、网页信息提取、生成或调试 Python 代码等。
总消息数不少于 150 条，或总对话轮次不少于 100 轮。
鼓励使用同一任务对比不同 AI 模型或不同提示策略。

2. 我们的选择适合场景 B 和场景 C，可以结合一下

场景 B：提示词策略对比

研究问题示例：零样本、少样本、思维链提示下，AI 回复质量有何差异？不同提示词策略下，代码一次通过率是否不同？
建议采集：提示词编号和策略类型、提示词全文、模型完整回复、执行结果、模型参数。
可分析指标：首次通过率、澄清次数、平均轮次、回复长度、错误率。
可视化方向：分组柱状图、平行坐标图、提示词策略对比热力图。

场景 C：多模型对比

研究问题示例：不同模型在相同任务下的代码正确率有何差异？哪个模型的错误修复效率更高？
建议采集：模型名称和版本、统一任务说明、每次运行的完整日志、代码、执行结果、错误信息、响应时间、Token 消耗。
可分析指标：错误发生率、首次修复成功率、平均修复轮次、工具调用次数、响应时间。
可视化方向：分组箱线图、散点图、雷达图、模型对比热力图。

3. 我们要选择制作交互系统，以下为要求

选项 B：可视交互系统

要求：构建一个支持数据探索与洞察的可视交互系统。
必须包含：

- 一个明确的分析目标：如“比较不同任务下 AI 的错误恢复模式”。
- 数据管道：日志解析 → 行为分类 → 结构化数据。
- 至少 3 个核心交互视图，例如：
  - 行为时间线或交互树；
  - 交互模式分布或错误类型图；
  - 原始对话/日志详情面板。
- 交互联动：至少实现一种联动，如筛选、点击、悬停、详情联动。
- 案例洞察：用系统探索出一个具体发现，并写成短报告。
- 可运行交付：代码仓库 + README + 演示。
  提交形式：可运行系统、代码仓库、案例报告。

🐵 清洗数据

2. 系统组

```
学号_姓名_AI对话行为分析_系统/
├── README.md
├── app/
│   └── （可运行系统代码）
├── data/
│   ├── raw/
│   ├── processed/
│   └── data_dictionary.md
├── report/
│   └── 案例报告.pdf
└── presentation/
    └── 答辩PPT.pdf
```

3. 通用要求

- README 给出代码运行说明，数据和代码可以运行复现提交的可视化图表；
- 代码路径使用相对路径；
- 原始数据如过大，可提供下载说明；
- 5～6分钟汇报视频，分辨率1080P，画面清晰，音画同步；
- PPT建议8～12页；
- 重点展示研究问题、关键图表、主要发现和项目反思。

4. 评分要求

评分项目	分值	具体评分要求
研究问题与选题	8	问题具体、系统目标明确、有探索价值
数据采集与伦理	8	采集方式规范、匿名化充分、引用完整
数据清洗与分类	15	清洗合理、分类清晰、数据管道完整
指标计算与分析	15	指标定义正确、统计合理、解释到位
可视化质量	15	视图设计合理、信息准确、标注完整
系统功能与交互	20	视图可交互、联动有效、系统可运行
洞察与案例	9	能利用系统发现具体行为模式并解释
代码与可复现性	5	代码结构清晰、README 完整、可复现
文档与答辩	5	报告规范、演示清晰、能解释技术选择
合计	100	

《数据分析与可视化实践》课程设计题目二

AI 对话数据与智能体行为分析

一、课程设计基本信息

- 总分：100 分
- 完成形式：小组项目，4～5 人
- 主要工具：Python、ECharts、D3.js、Plotly、Vega-Lite 等

二、课程设计目标

学生通过自行采集与 AI 的对话数据或智能体运行日志，完成从数据获取、清洗、分析到可视化表达的完整流程，达到以下目标：

- 掌握对话数据或智能体日志的采集、匿名化和伦理规范。
- 掌握 JSON/CSV 等格式日志的读取、解析和结构化方法。
- 能够根据研究问题设计数据采集方案，选择合适的分析维度。
- 能够根据数据特点选择恰当的可视化形式，展示行为序列、模式、关系和差异。
- 能够使用 Python 可视化库，或 ECharts、D3.js 等前端图表库，制作静态或交互式图表。
- 能够依据分析结果形成有证据支持的结论，讲述数据故事或构建可探索系统。
- 理解行为分析的局限性，区分描述性发现与因果解释。

三、数据来源与采集要求

1. 数据来源

自行采集与 AI 的对话数据或智能体运行日志，可选来源包括（不限于）：

- 自己与 ChatGPT、Claude、Gemini、文心一言、通义千问等通用 AI 的对话记录；
- 自己运行编码智能体产生的日志；
- 自己搭建的简单智能体的运行记录。

2. 任务设置

至少设计 2～3 个不同任务，例如：数据读取与统计、文件处理、图表生成、网页信息提取、生成或调试 Python 代码等。
总消息数不少于 150 条，或总对话轮次不少于 100 轮。
鼓励使用同一任务对比不同 AI 模型或不同提示策略。

3. 研究方向参考

可根据兴趣选择以下方向之一，也可自主提出方向：

场景 A：通用对话行为分析

研究问题示例：在完成任务的过程中，AI 主要采用了哪些交互模式？对话轮次与任务完成质量之间有什么关系？
建议采集：完整对话文本、任务编号、运行编号、轮次编号、模型名称、响应时间。
可分析指标：对话轮次、交互模式占比、任务完成率、用户纠正次数。
可视化方向：行为时间线、交互模式分布图、任务对比箱线图。

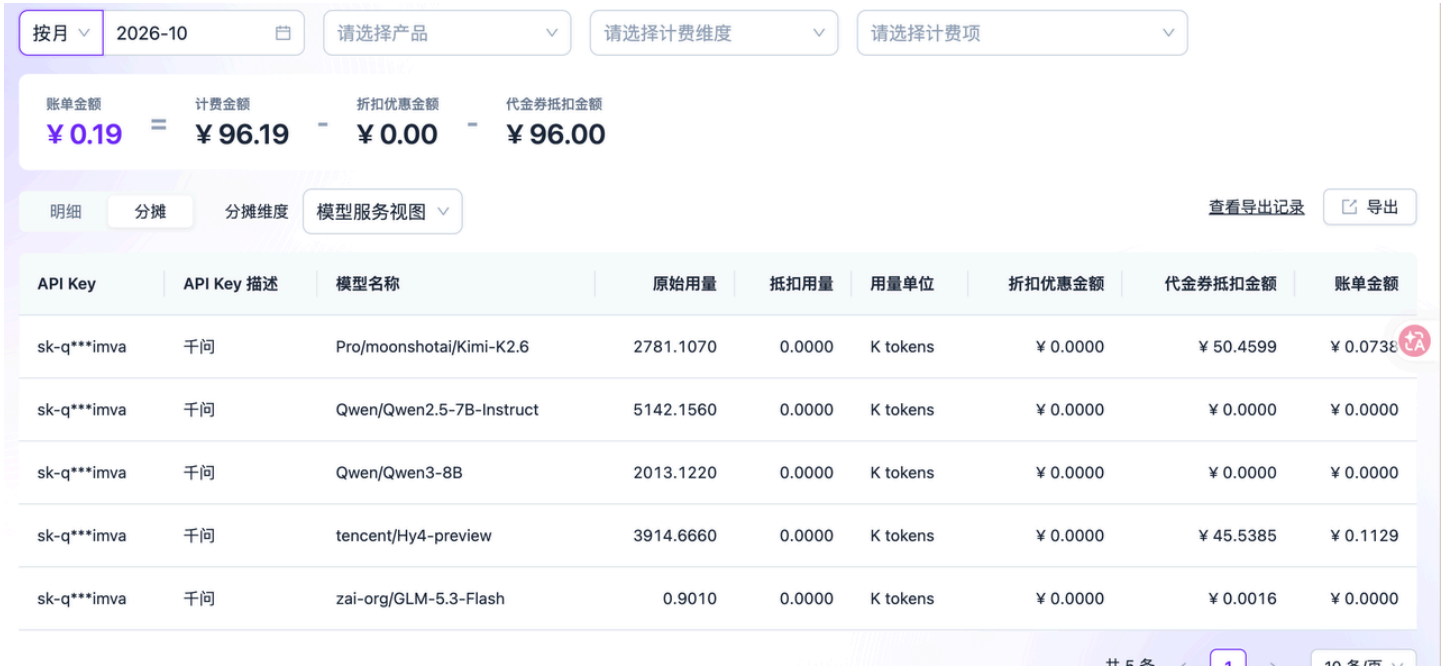
场景 B：提示词策略对比

1.1 初步分工

序号	任务	具体内容	负责
0	数据采集	① 还需约 50 元经费；② Qwen3 预计还需 8 小时运行完成	zzy
1	讨论方案	全员开会确定制作内容、叙事逻辑；利用腾讯会议记录整理项目大纲	全员
2	数据清洗与草图	清洗实验数据，画论文草图/我们要画的图	1 人
3	交互系统开发	根据草图实现交互系统；答辩者需理解系统代码，重点准备代码相关问题	1 人
4	模拟效果讨论	全员开会讨论系统效果，结合腾讯会议记录、原论文和系统截图，生成文档及 PPT 初稿	全员
5	文档与 PPT 制作	根据初稿完善项目文档和答辩 PPT	1 人
6	视频制作与答辩	录制系统演示视频，准备并完成答辩	1 人
7	最终检查与提交	检查所有成果，按照课程要求提交相应材料	zzy

1.2 限制（余额不足，时间还需一天）

① 还需约 50 元经费（舍弃掉 kimi，kimi 太 tm 贵了，只用 hy4）；② Qwen3 预计还需 8 小时运行完成



截至 10 月 19 日 09:37：

模型	已完成 / 总数	进度	状态
DeepSeek	18,600 / 18,600	100%	已完成
Qwen2.5-7B	18,600 / 18,600	100%	已完成
Qwen3-8B	4,623 / 18,600	24.9%	刚恢复运行
Kimi-K2.6	6,025 / 18,600	32.4%	暂停
Hy4-preview	11,556 / 18,600	62.1%	暂停

全部实验跑完，预计还需要约 140 元，建议预算留到 160–180 元。
只跑完当前的免费 Qwen3，新增 API 费用为 0 元。

结合截图账单和本地实验记录：

模型	已完成 / 总回答数	剩余费用粗估
Kimi-K2.6	6,025 / 18,600	约 95–105 元
Hy4-preview	11,556 / 18,600	约 40–45 元
Qwen3-8B	约 4,700 / 18,600	0 元
DeepSeek、Qwen2.5	均已完成	无剩余费用

1.3 选择讨论时间

时间段	周一	周二	周三	周四	周五	周六
08:30–10:05	🟢	❌	🟢	🟢	🟢	🟢
10:25–12:00	🟢	❌	🟢	🟢	🟢	🟢
13:30–15:05	🟢	❌	🟢	🟢	🟢	🟢
15:25–17:00	🟢	❌	🟢	🟢	🟢	🟢
18:30–20:05	🟢	🟢	🟢	🟢	🟢	🟢
其他时间	自定义	自定义	自定义	自定义	自定义	自定义

填写规则： 🟢 表示暂无人标记忙碌，❌ 表示至少一人没空。每个人只把自己没空的时间改成 ❌，不要把别人标记的 改回 🟢

1.4 论文结论

论文结论速查 · 结论 → 图表支撑 → 指标如何计算 → 图表如何看

How Well do LLMs Compress Their Own Chain-of-Thought? A Token Complexity Approach

Lee、Che、Peng（Columbia Business School），arXiv 2503.01141 · 图表为原文截图，页码指原文页码

先说两个词

思维链：模型给出答案前写下的解题过程，像草稿纸。**token**：模型计算字数的单位，大约半个到一个英文单词，写得越多越费钱。

论文的做法：给 5 个模型发 31 种“写短一点”的指令（如“最多 10 个词”“只写算式”“用中文”），在 3 个数学题库上各做 500 题，看每种指令下写了多长、答对多少。

四条结论一览

(1) 答得准不准，主要看写了多长，不看怎么写。

(2) 每道题都有一个“至少要写多少 token 才能答对”的门槛。

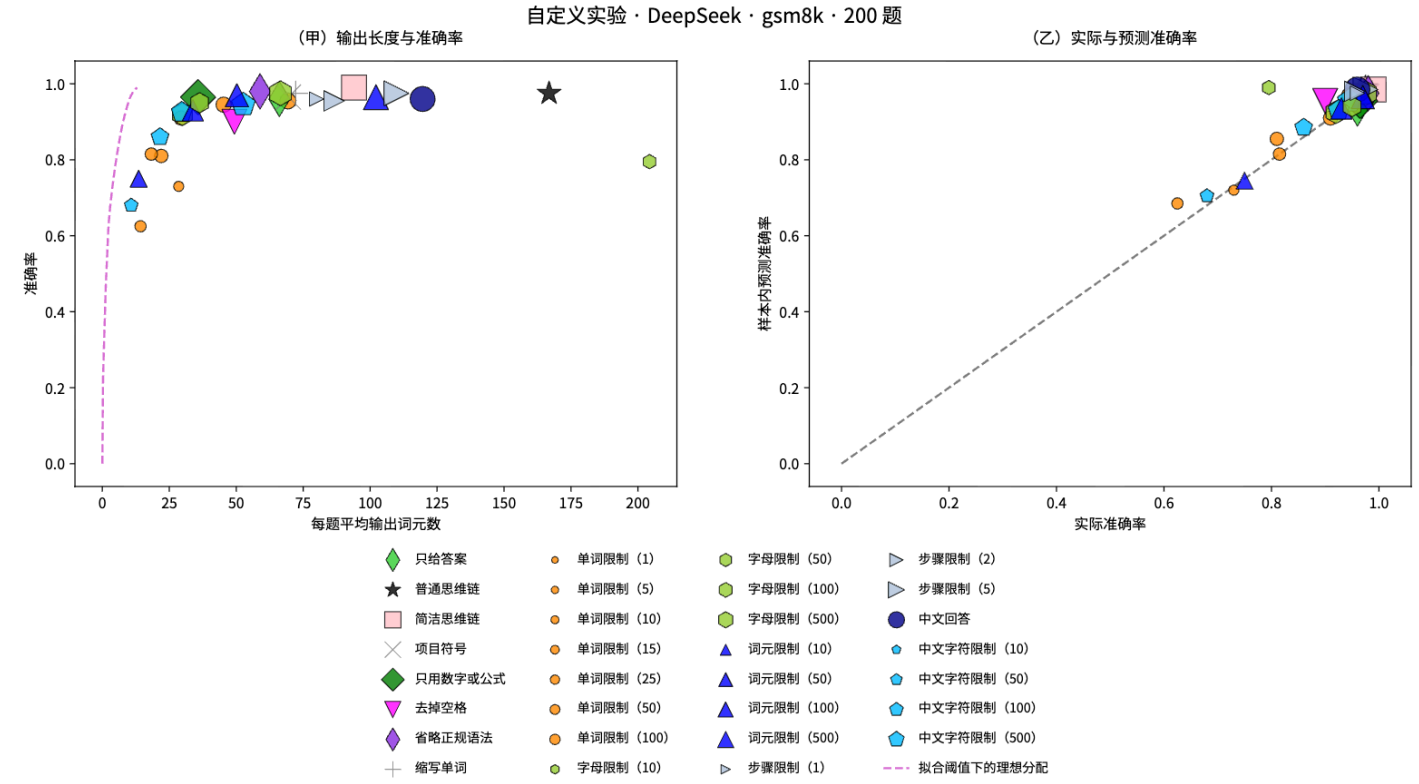
(3) 现有的压缩方法离理论极限还很远。

(4) 要逼近极限，得按题目难度分配长度；难点是模型估不准难度。

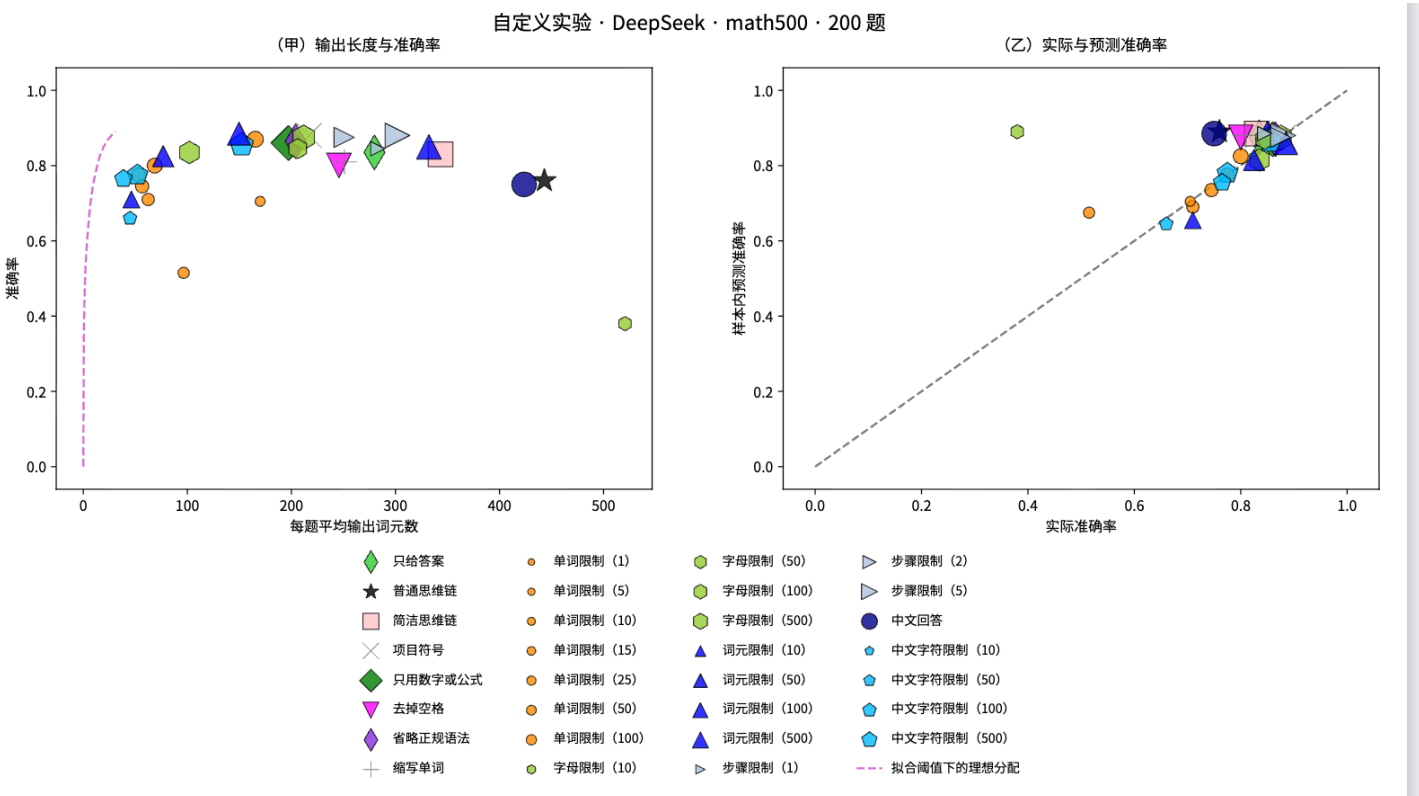
TokenComplexity_结论速查.pdf

1.5 已有结果

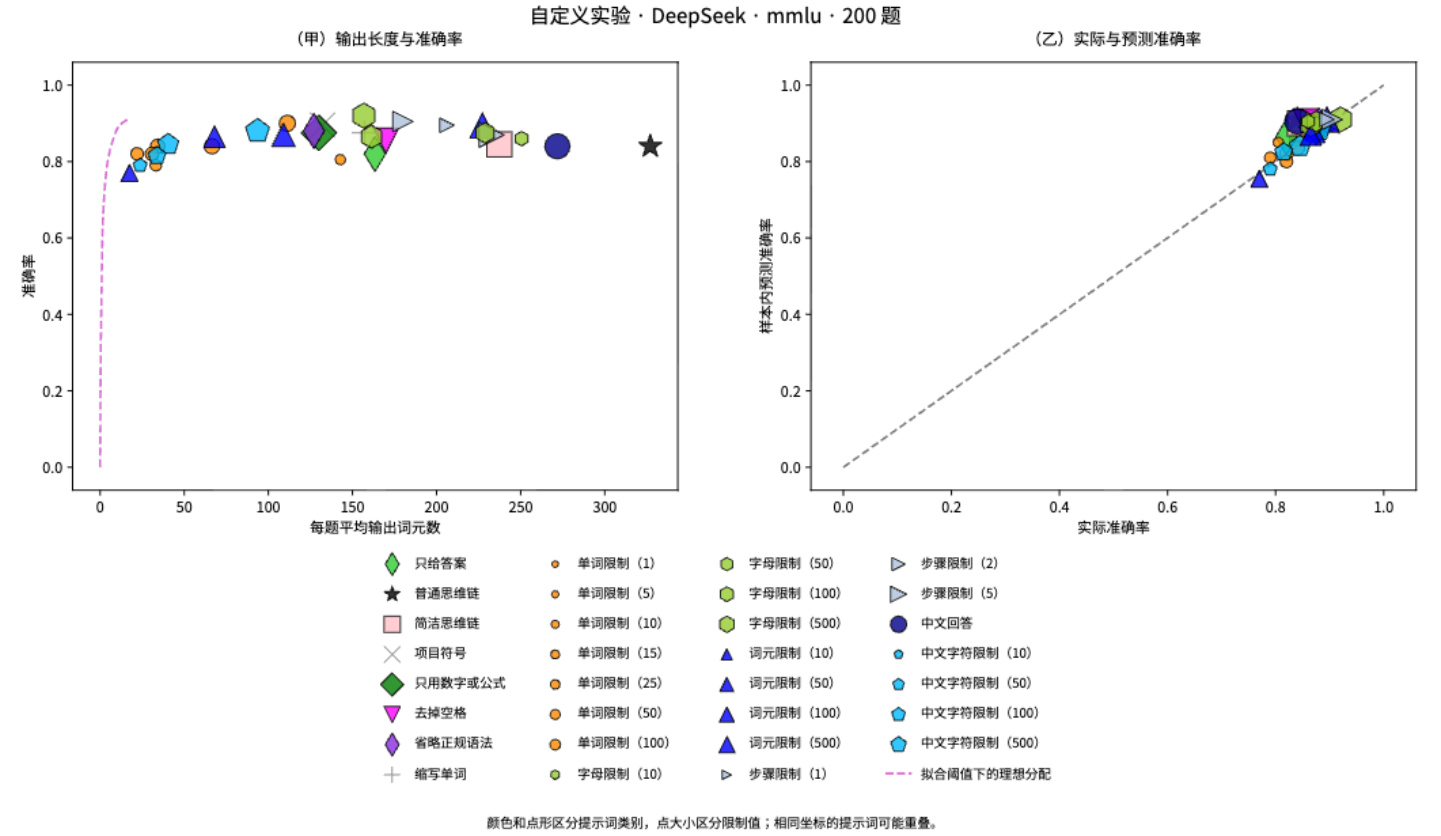
deepseek



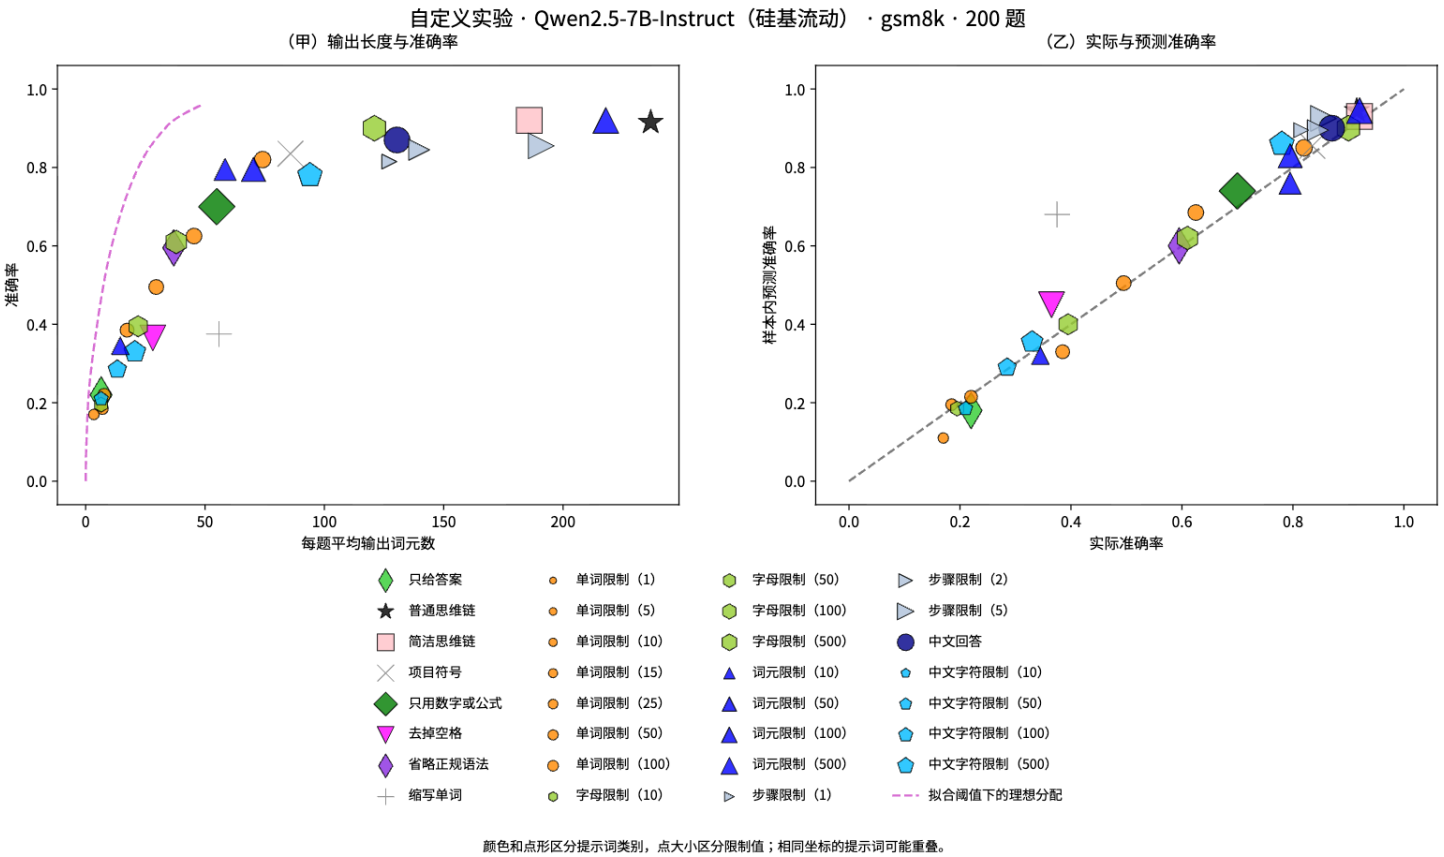
颜色和点形区分提示词类别，点大小区分限制值；相同坐标的提示词可能重叠。

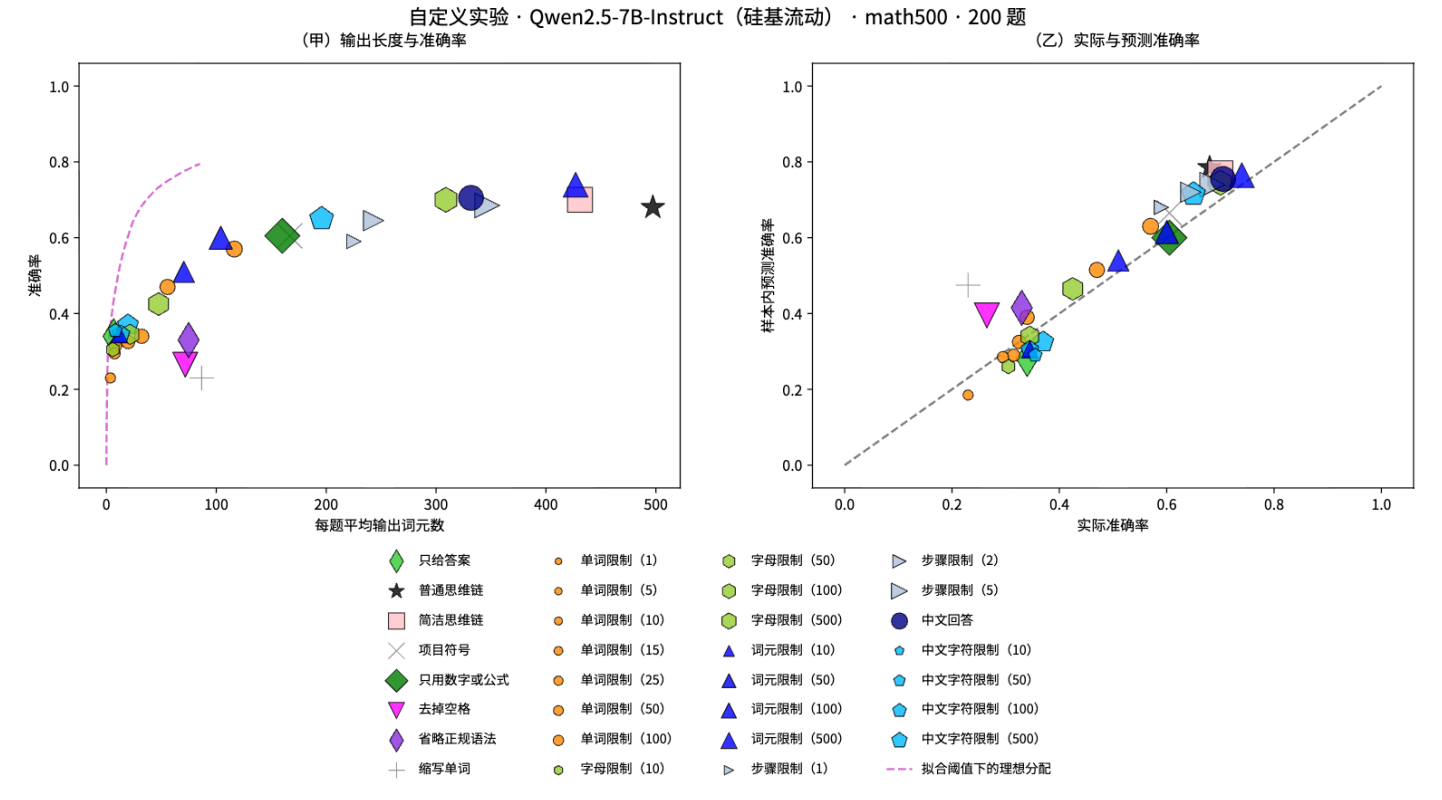


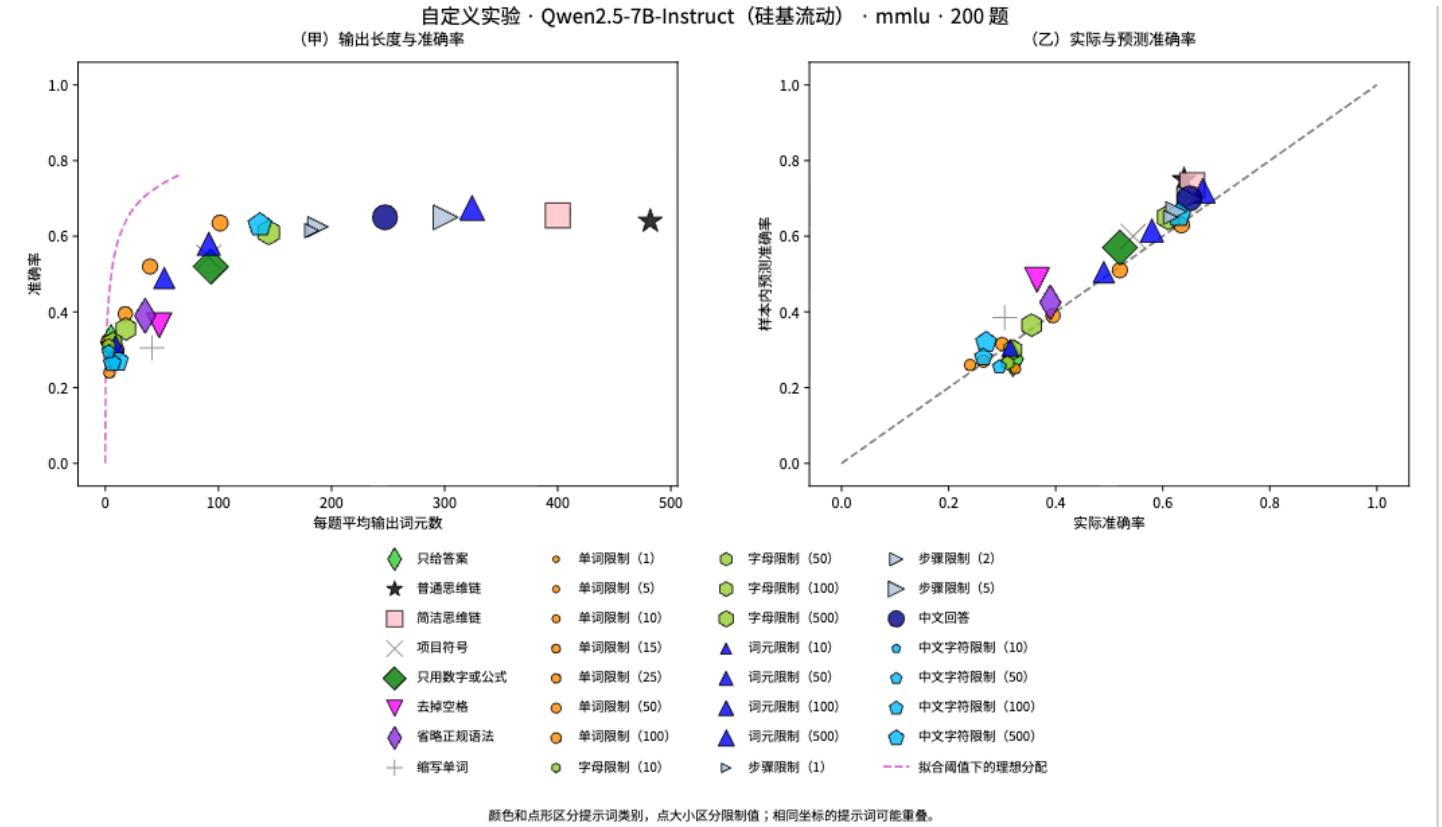
颜色和点形区分提示词类别，点大小区分限制值；相同坐标的提示词可能重叠。


自定义实验 · DeepSeek · mmlu · 200 题
（甲）输出长度与准确率
准确率
每题平均输出词元数
（乙）实际与预测准确率
样本内预测准确率
实际准确率
只给答案
普通思维链
简洁思维链
项目符号
只用数字或公式
去掉空格
省略正规语法
缩写单词
单词限制（1）
单词限制（5）
单词限制（10）
单词限制（15）
单词限制（25）
单词限制（50）
单词限制（100）
字母限制（10）
字母限制（50）
字母限制（100）
字母限制（500）
词元限制（10）
词元限制（50）
词元限制（100）
词元限制（500）
步骤限制（1）
步骤限制（2）
步骤限制（5）
中文回答
中文字符限制（10）
中文字符限制（50）
中文字符限制（100）
中文字符限制（500）
拟合阈值下的理想分配
颜色和点形区分提示词类别，点大小区分限制值；相同坐标的提示词可能重叠。

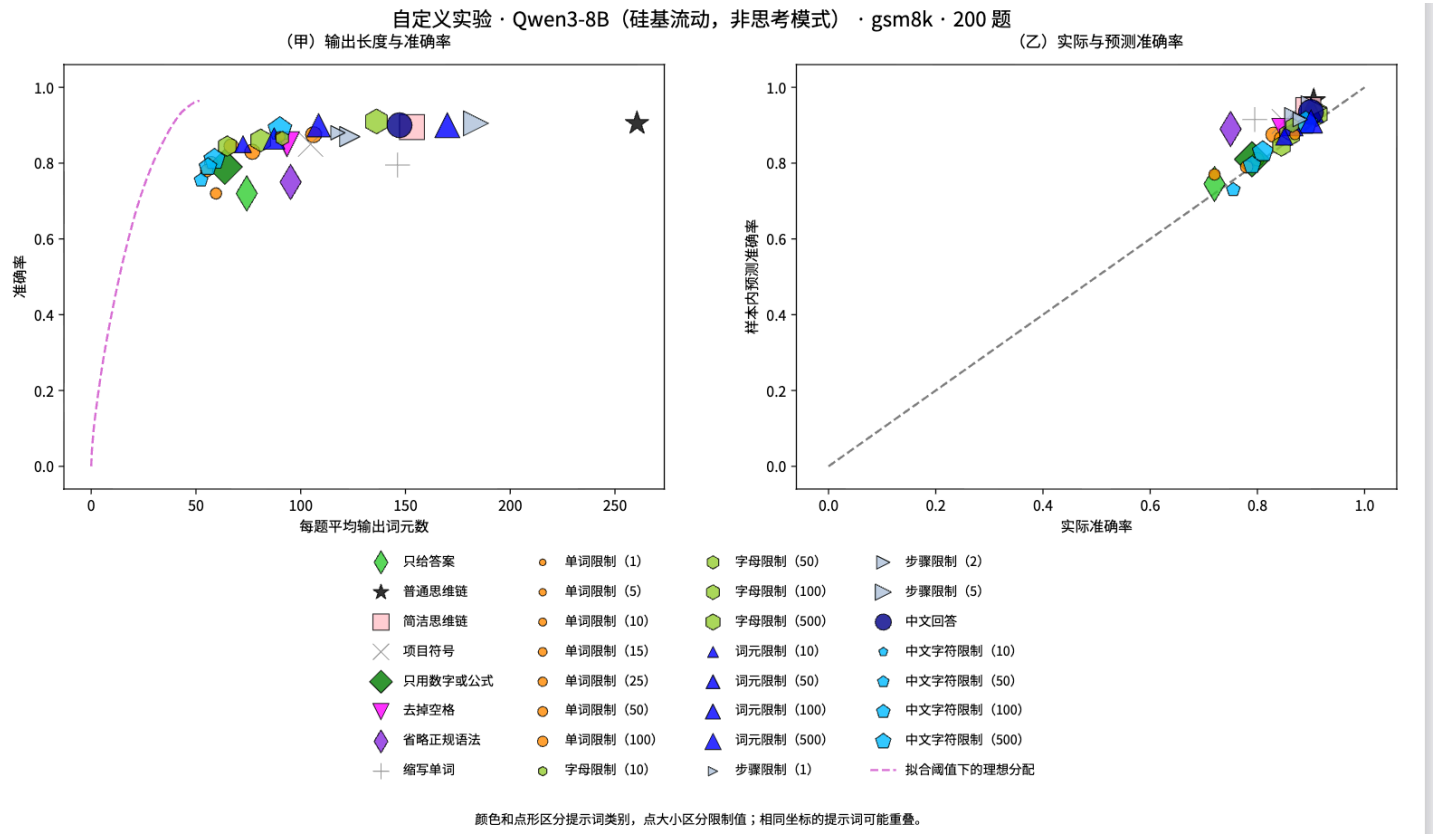
qwen2.5


自定义实验 · Qwen2.5-7B-Instruct（硅基流动） · gsm8k · 200 题
（甲）输出长度与准确率
准确率
每题平均输出词元数
（乙）实际与预测准确率
样本内预测准确率
实际准确率
只给答案
普通思维链
简洁思维链
项目符号
只用数字或公式
去掉空格
省略正规语法
缩写单词
单词限制（1）
单词限制（5）
单词限制（10）
单词限制（15）
单词限制（25）
单词限制（50）
单词限制（100）
字母限制（10）
字母限制（50）
字母限制（100）
字母限制（500）
词元限制（10）
词元限制（50）
词元限制（100）
词元限制（500）
步骤限制（1）
步骤限制（2）
步骤限制（5）
中文回答
中文字符限制（10）
中文字符限制（50）
中文字符限制（100）
中文字符限制（500）
拟合阈值下的理想分配
颜色和点形区分提示词类别，点大小区分限制值；相同坐标的提示词可能重叠。

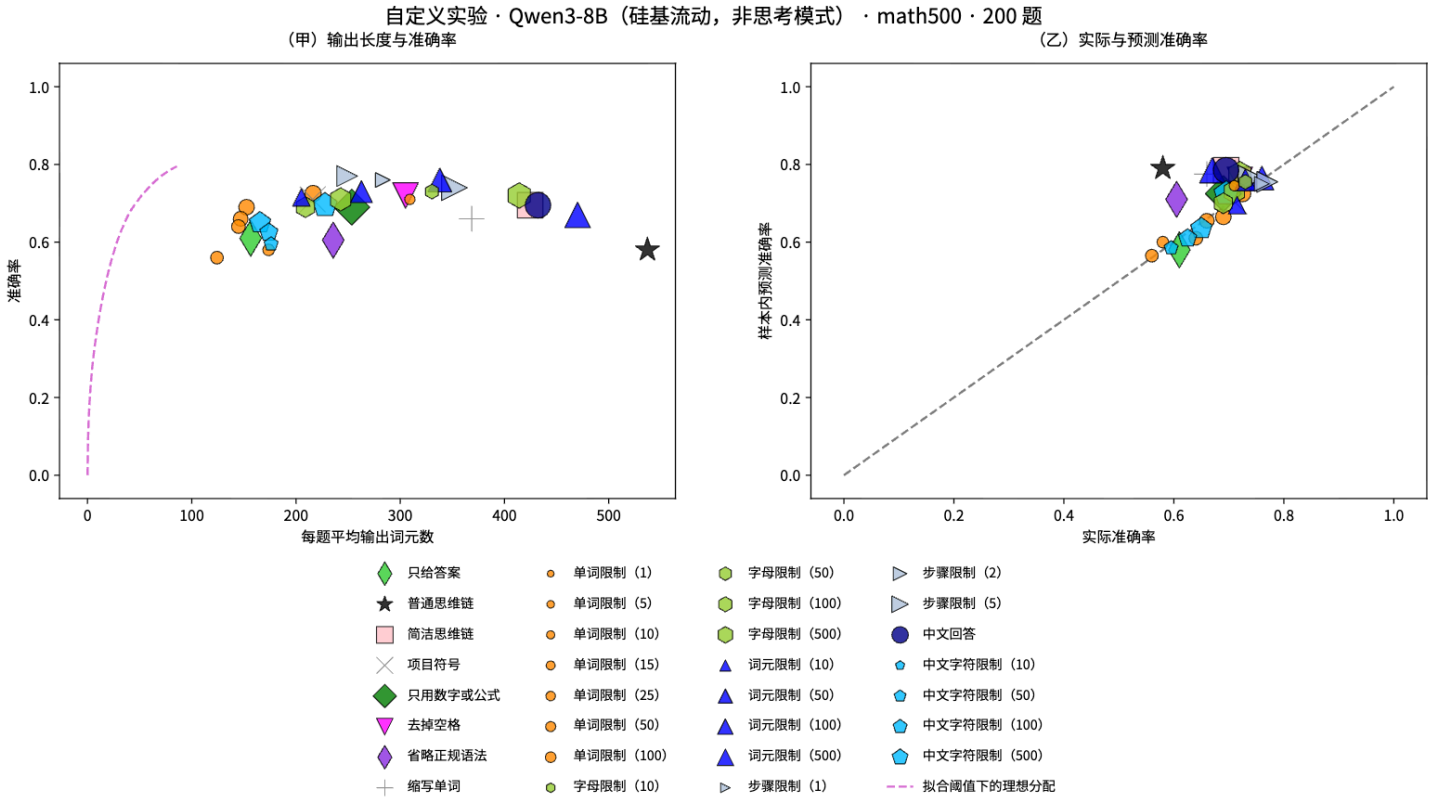

自定义实验 · Qwen2.5-7B-Instruct（硅基流动） · math500 · 200 题
（甲）输出长度与准确率
（乙）实际与预测准确率
准确率
每题平均输出词元数
样本内预测准确率
实际准确率
只给答案
普通思维链
简洁思维链
项目符号
只用数字或公式
去掉空格
省略正规语法
缩写单词
单词限制（1）
单词限制（5）
单词限制（10）
单词限制（15）
单词限制（25）
单词限制（50）
单词限制（100）
字母限制（10）
字母限制（50）
字母限制（100）
字母限制（500）
词元限制（10）
词元限制（50）
词元限制（100）
词元限制（500）
步骤限制（1）
步骤限制（2）
步骤限制（5）
中文回答
中文字符限制（10）
中文字符限制（50）
中文字符限制（100）
中文字符限制（500）
拟合阈值下的理想分配
颜色和点形区分提示词类别，点大小区分限制值；相同坐标的提示词可能重叠。


自定义实验 · Qwen2.5-7B-Instruct（硅基流动） · mmlu · 200 题
（甲）输出长度与准确率
（乙）实际与预测准确率
准确率
每题平均输出词元数
样本内预测准确率
实际准确率
只给答案
普通思维链
简洁思维链
项目符号
只用数字或公式
去掉空格
省略正规语法
缩写单词
单词限制（1）
单词限制（5）
单词限制（10）
单词限制（15）
单词限制（25）
单词限制（50）
单词限制（100）
字母限制（10）
字母限制（50）
字母限制（100）
字母限制（500）
词元限制（10）
词元限制（50）
词元限制（100）
词元限制（500）
步骤限制（1）
步骤限制（2）
步骤限制（5）
中文回答
中文字符限制（10）
中文字符限制（50）
中文字符限制（100）
中文字符限制（500）
拟合阈值下的理想分配
颜色和点形区分提示词类别，点大小区分限制值；相同坐标的提示词可能重叠。

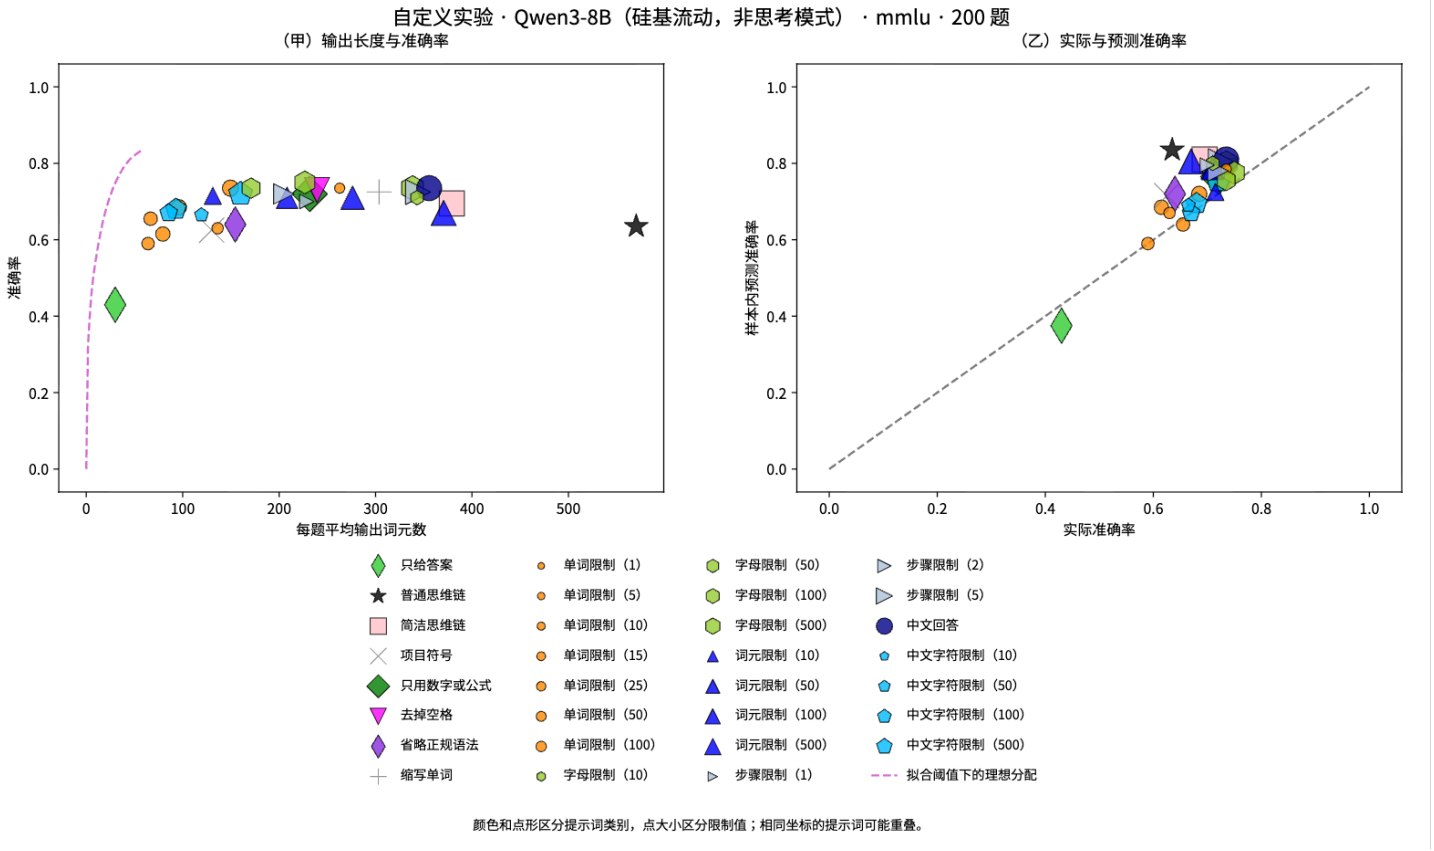
qwen3



颜色和点形区分提示词类别，点大小区分限制值；相同坐标的提示词可能重叠。



颜色和点形区分提示词类别，点大小区分限制值；相同坐标的提示词可能重叠。



1. 待办

本周：

1. ✅3 份 api 密钥
2. zzy：接密钥，得到数据，复现论文图表，制作一个可交互系统初稿
3. 文丽：图表论文调研，审核之后复现数据采集以及图表生成

   禹潼：代码论文调研，审核之后复现数据采集以及图表生成
4. 承文：进一步分析三方数据看是否有新结论，审核论文