《数据分析与可视化实践》课程设计题目一

世界人口与经济发展差异分析

一、课程设计基本信息

- 课程名称：数据分析和可视化实践
- 课程设计题目：世界人口与经济发展差异分析
- 适用对象：本科生
- 完成形式：小组项目，4～5 人
- 实践周期：1～2周
- 主要工具：Python、Jupyter Notebook
- 推荐库：Pandas、NumPy、Matplotlib、Seaborn、Plotly
- 总分：100分

二、课程设计目标

学生通过世界各国人口与经济发展数据，完成从数据获取到结论表达的完整分析流程，达到以下目标：

1. 掌握公开数据的获取、读取和管理方法。
2. 掌握缺失值、重复值、异常值及数据类型的处理方法。
3. 能够按照国家、地区、收入水平和年份进行分组统计。
4. 能够计算增长率、占比、排名和综合指标。
5. 能够根据数据特点选择恰当的可视化形式。
6. 能够利用 Plotly 制作交互式图表。
7. 能够依据分析结果形成有证据支持的结论。
8. 理解相关关系与因果关系的区别，认识数据分析的局限性。

三、数据来源

建议使用世界银行开放数据。

1. 必选指标

指标	世界银行代码	主要用途
总人口	`SP.POP.TOTL`	分析人口规模及变化
GDP（现价美元）	`NY.GDP.MKTP.CD`	分析经济总量
人均GDP（现价美元）	`NY.GDP.PCAP.CD`	衡量人均经济发展水平
城镇人口占比	`SP.URB.TOTL.IN.ZS`	分析城市化水平

2. 自选指标

学生至少补充两个指标，例如：

- 人口增长率；
- 预期寿命；
- 失业率；
- 互联网使用率；
- 高等教育入学率；
- 产业增加值占比；
- CO_2排放量；
- 贫困人口比例；
- 人均能源消耗。

3. 数据范围

- 建议研究年份：2000—2024年；
- 必须包含不少于30个国家或经济体；
- 应覆盖亚洲、欧洲、非洲、北美洲、南美洲和大洋洲；
- 允许选择全球数据，也可以重点比较“一带一路”、G20、金砖国家或特定区域；
- 若部分指标最新年份缺失，可采用“最近可用年份”，但必须明确说明。

四、核心研究任务

任务一：提出研究问题

学生应围绕题目提出不少于5个具体问题，至少包括：

1. 不同国家人口规模和经济总量存在怎样的差异？
2. 研究期内人口和GDP的变化趋势如何？
3. 人口规模与GDP总量之间是否存在相关关系？
4. 人均GDP与城市化率之间存在怎样的关系？
5. 不同地区或收入组的发展水平有何差异？

此外，应自主提出至少一个拓展问题，例如：

- 哪些国家经济增长较快，但人均发展水平仍然较低？
- 哪些国家人口增长与经济增长不协调？
- 城市化水平提高是否总是伴随着人均GDP增长？
- 不同收入组国家的发展差距是否扩大？
- 某次国际事件前后，各国经济指标发生了什么变化？

任务二：数据获取与整合

学生需要：

1. 下载或通过接口获取各项指标数据；
2. 保存原始数据，不得直接覆盖；
3. 将不同指标按照国家代码和年份进行合并；
4. 补充国家所属大洲、地区或收入组信息；

5. 建立规范的数据字典；
6. 输出一份整合后的分析数据集。

任务三：数据清洗

至少完成以下工作：

- 检查字段名称和数据类型；
- 将宽表转换成长表，或说明保留宽表的理由；
- 处理重复记录；
- 统计各字段的缺失数量及缺失比例；
- 识别非国家经济体、地区汇总项和全球汇总项；
- 检查人口、GDP等指标中的零值、负值和异常值；
- 统一国家名称、国家代码和年份格式；
- 说明删除、填补或保留缺失值的依据。

不得在没有说明的情况下直接使用均值填补所有缺失值。

任务四：指标计算

至少计算以下派生指标：

1. GDP年度增长率；
2. 人口年度增长率；
3. 各国GDP占所在地区GDP的比例；
4. 各国人口占所在地区人口的比例；
5. 研究期内GDP和人口的累计增长率；
6. 最新年份GDP、人均GDP等指标的排名。

增长率计算应注意分母为零、缺失年份和极端值问题。

任务五：探索性分析

至少完成：

- 数据总体规模和结构说明；
- 数值指标的描述性统计；
- 各地区人口与GDP总量比较；
- 各收入组人均GDP分布比较；
- 重点国家人口及经济趋势比较；
- 指标间相关关系分析；
- 异常国家或特殊发展模式识别。

分析不能停留在“最大、最小、上升、下降”等简单描述，应结合增长速度、地区背景和指标关系进行解释。

五、可视化要求

至少制作8幅有效图表，其中必须包含：

图表类型	数量要求	参考内容
时间序列折线图	≥1	重点国家GDP或人口变化
排名条形图	≥1	GDP、人均GDP或增长率前十名
散点图或气泡图	≥1	人口、GDP、人均GDP之间的关系
相关性热力图	≥1	多项发展指标之间的相关性
地图	≥1	各国人均GDP或人口空间分布
分布比较图	≥1	不同地区的箱线图或小提琴图
Plotly交互图	≥1	动态地图、动态气泡图或交互折线图
自选图表	≥1	坡度图、面积图、雷达图等

图表必须做到：

- 有明确标题；
- 标注坐标轴名称和计量单位；
- 图例、颜色和字体清晰；
- 不使用失真的坐标轴；
- 不使用无实际意义的3D图；
- 颜色能够区分类别或表达数值大小；
- 图表下方给出简短的数据发现；
- 注明数据年份和数据来源。

六、分析结论要求

最终报告至少给出8条分析发现，其中：

- 至少3条描述趋势或地区差异；
- 至少2条解释指标间关系；
- 至少1条讨论异常国家或特殊现象；
- 至少1条说明数据局限；
- 至少1条提出进一步研究方向。

所有结论必须能够在统计结果或图表中找到依据。不能把相关性直接表述为因果关系。

七、提交成果

1. Jupyter Notebook

Notebook应包含：

1. 项目背景与研究问题；
2. 数据来源与字段说明；
3. 数据读取；
4. 数据清洗；

5. 指标构建；
6. 探索性分析；
7. 数据可视化；
8. 主要结论；
9. 数据局限与反思。

Notebook必须能够按照单元格顺序完整运行，不得出现大量报错、无关测试代码或失效路径。

2. 分析报告

- 建议字数：3000～5000字；
- 格式：PDF；
- 内容包括摘要、研究问题、数据说明、分析方法、结果、结论和局限；
- 图表应编号，并在正文中引用；
- 数据来源和参考文献应规范列出。参考文献格式遵照本科毕业论文要求，采用 GB/T 7714-2015。

3. 数据文件

提交：

- 原始数据；
- 清洗后的数据；
- 数据字典；
- 数据来源说明。

如原始文件过大，可提供正式下载地址及下载说明。

4. 其他材料

- 5～6分钟汇报视频，分辨率1080P，画面清晰，音画同步；
- PPT建议8～12页；
- 重点展示研究问题、关键图表、主要发现和项目反思；

5. 推荐目录结构

```
学号_姓名_世界人口经济分析/
├── README.md
├── notebook/
│   └── analysis.ipynb
├── data/
│   ├── raw/
│   └── processed/
├── figures/
├── report/
│   └── 分析报告.pdf
└── presentation/
    └── 答辩PPT.pdf
```

八、评分标准

评分项目	分值	具体评分要求
选题理解与研究问题	8	背景清楚；研究范围明确；问题具体且可通过数据回答；具有一定自主探索性
数据获取与来源规范	8	数据来源权威；指标选择合理；数据范围符合要求；引用信息完整
数据清洗与整合	15	正确处理类型、重复值、缺失值、异常值；多表合并准确；处理依据说明充分
指标计算与统计分析	15	增长率、占比和排名计算正确；分组统计合理；能够正确解释统计结果
可视化质量	20	图表类型恰当、信息准确、标注完整、配色协调；包含地图和交互图；避免误导性表达
分析深度与结论	15	结论有数据依据；能够解释地区差异和指标关系；识别异常现象；不夸大因果关系
代码质量与可复现性	8	结构清晰；变量命名合理；适当封装重复操作；Notebook可完整运行；路径使用规范
报告规范与表达	6	结构完整、语言准确、图文对应、格式统一、引用规范
答辩表现	5	时间控制合理；表达清晰；能够解释分析过程并准确回答问题
合计	**100**	

九、评分等级说明

优秀：90～100分

- 数据处理规范、准确且可复现；
- 研究问题有一定深度；
- 图表美观、有效且具有较强叙事性；
- 能够从多个指标解释国家和地区差异；
- 结论充分，并能主动讨论局限和反常现象。

良好：80～89分

- 完成全部核心任务；
- 数据处理和指标计算基本正确；
- 图表规范，结论有数据支持；
- 分析具有一定深度，但自主探索或综合解释稍弱。

中等：70～79分

- 完成大部分任务；
- 存在少量数据处理或可视化问题；
- 分析以描述性统计为主；
- 结论基本正确，但缺乏深入解释。

及格：60～69分

- 基本完成数据读取、简单清洗和图表制作；
- 核心任务存在遗漏；
- 图表或结论较为简单；

- Notebook能够部分运行，但规范性不足。

不及格：60分以下

- 未完成主要分析任务；
- 数据来源不明或数据处理严重错误；
- 多数图表无法正确表达数据；
- Notebook无法运行；
- 报告内容与代码、数据明显不一致。

十、扣分与学术诚信规定

出现以下情况，可在对应项目之外追加扣分：

- 未注明数据来源：扣5～10分；
- 未提交原始数据或下载说明：扣3分；
- Notebook不能按顺序运行：扣3～10分；
- 图表缺少标题、单位或图例：每幅扣1分；
- 结论与图表明显不符：每处扣2～5分；
- 使用未来数据填补历史缺失值且未说明：扣3～5分；
- 大量代码与他人高度雷同：按学校学术诚信规定处理；
- 伪造数据、篡改结果或直接提交他人成果：课程设计成绩记零。

允许合理使用生成式人工智能辅助解释代码、排查错误或优化表达，但学生必须在报告中说明使用范围，并能够在答辩中解释所有提交的代码和结论。

“自选指标”建议从世界银行开放数据下载，可以保持国家代码、年份和数据格式与必选指标一致，便于后续合并。

附录：自选指标与数据获取参考

推荐指标及下载入口

自选指标	指标代码	下载入口
人口增长率（年度%）	`SP.POP.GROW`	世界银行人口增长率
出生时预期寿命	`SP.DYN.LE00.IN`	世界银行预期寿命
失业率	`SL.UEM.TOTL.ZS`	世界银行失业率
互联网使用率	`IT.NET.USER.ZS`	世界银行互联网使用率
高等教育毛入学率	`SE.TER.ENRR`	世界银行高等教育入学率
CO_2人均排放量	`EN.ATM.CO2E.PC`	世界银行人均碳排放
贫困人口比例	`SI.POV.DDAY`	世界银行国际贫困线指标
人均能源使用量	`EG.USE.PCAP.KG.OE`	世界银行人均能源使用量
工业增加值占GDP比例	`NV.IND.TOTL.ZS`	世界银行工业增加值
农业增加值占GDP比例	`NV.AGR.TOTL.ZS`	世界银行农业增加值

其中，预期寿命数据目前覆盖到2024年；人口增长率覆盖1961—2024年；互联网使用率和失业率的部分国家已有2025年数据。各指标最新年份不同，因此合并后出现缺失值是正常现象。

最推荐的两个指标

建议课程设计统一选择：

1. **出生时预期寿命：** **`SP.DYN.LE00.IN`**
2. **互联网使用率：** **`IT.NET.USER.ZS`**

这样可以分析：

- 人均GDP与预期寿命的关系；
- 人均GDP与互联网普及率的关系；
- 不同收入组的健康和数字化差距；
- 经济增长是否伴随着社会发展水平提高。

这两个指标覆盖国家较多，也比较容易解释。贫困率、高等教育入学率和能源使用量的缺失相对较多，更适合作为拓展指标。

方法一：在网页上直接下载

进入某个指标页面后：

1. 找到页面中的“Download”；
2. 选择“CSV”；
3. 下载ZIP压缩包；
4. 解压后通常包含：

```
API_SP.DYN.LE00.IN_DS2_en_csv_v2_xxx.csv
Metadata_Country_API_SP.DYN.LE00.IN_DS2_en_csv_v2_xxx.csv
Metadata_Indicator_API_SP.DYN.LE00.IN_DS2_en_csv_v2_xxx.csv
```

分析时主要读取以 `API_` 开头的CSV文件。

世界银行CSV文件前几行通常是说明文字，可以这样读取：

```
import pandas as pd

life = pd.read_csv(
    "API_SP.DYN.LE00.IN_DS2_en_csv_v2_xxx.csv",
    skiprows=4
)

life.head()
```

方法二：使用世界银行 API

例如，获取2000—2024年所有国家的预期寿命：

```
import requests
import pandas as pd

url = (
    "https://api.worldbank.org/v2/country/all/"
    "indicator/SP.DYN.LE00.IN"
    "?format=json&date=2000:2024&per_page=20000"
)

result = requests.get(url, timeout=30).json()
records = result[1]

life = pd.DataFrame([
    {
        "country": item["country"]["value"],
        "country_code": item["countryiso3code"],
        "year": int(item["date"]),
        "life_expectancy": item["value"]
    }
    for item in records
])

life.head()
```

获取互联网使用率时，只需更换指标代码：

```
indicator = "IT.NET.USER.ZS"

url = (
    f"https://api.worldbank.org/v2/country/all/indicator/{indicator}"
    "?format=json&date=2000:2024&per_page=20000"
)
```

一次获取多个指标

```
import requests
import pandas as pd
from functools import reduce
```

```
indicators = {
    "SP.POP.TOTL": "population",
    "NY.GDP.MKTP.CD": "gdp",
    "NY.GDP.PCAP.CD": "gdp_per_capita",
    "SP.URB.TOTL.IN.ZS": "urban_rate",
    "SP.DYN.LE00.IN": "life_expectancy",
    "IT.NET.USER.ZS": "internet_rate"
}

def get_world_bank_data(indicator, column_name):
    url = (
        f"https://api.worldbank.org/v2/country/all/indicator/{indicator}"
        "?format=json&date=2000:2024&per_page=20000"
    )

    response = requests.get(url, timeout=30)
    response.raise_for_status()
    result = response.json()

    records = result[1]

    return pd.DataFrame([
        {
            "country": item["country"]["value"],
            "country_code": item["countryiso3code"],
            "year": int(item["date"]),
            column_name: item["value"]
        }
        for item in records
        if item["countryiso3code"]
    ])

dataframes = [
    get_world_bank_data(code, name)
    for code, name in indicators.items()
]

df = reduce(
    lambda left, right: pd.merge(
        left,
        right,
        on=["country", "country_code", "year"],
        how="outer"
    ),
    dataframes
)

df.head()
```

需要注意：`country/all` 返回的数据中包含“World”“High income”“East Asia & Pacific”等地区汇总项。正式进行国家比较时，应使用世界银行国家元数据识别并删除这些汇总项，不能只根据国家名称手工排除。