模型行为研究：输出、资料与反馈

输出、资料与反馈，怎样组织更有效？

推理 / 文档问答 / Python代码

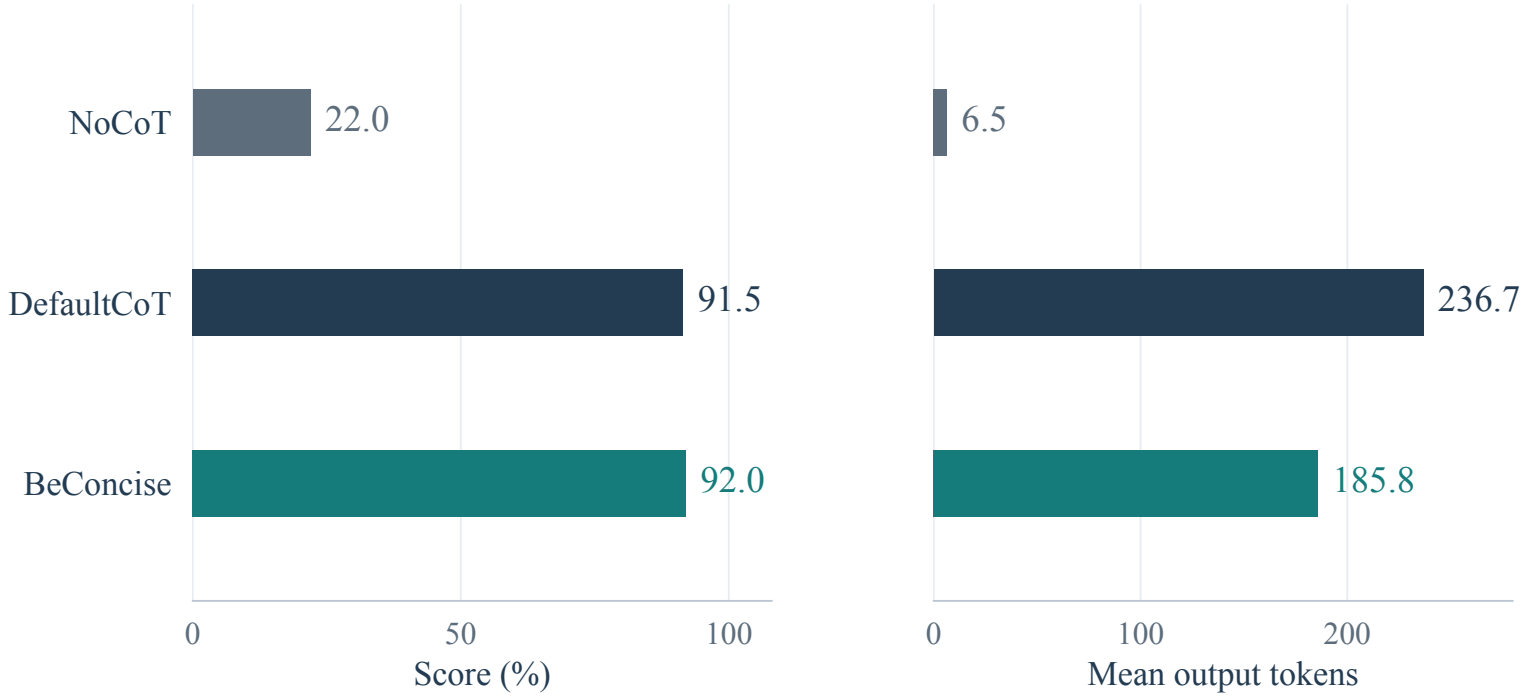
从完整数据管道出发，形成五条可解释、可追溯的发现。

数据规模与比较方式

推理提示	74,400	600题，四模型，31提示
文档问答	74,800	200题，多种资料与提示条件
代码生成	90,210	194题，三模型，五次独立采样
文档位置实验	3,600	200题，两模型，9个证据位置
多轮代码修复	5,576	164题，两模型，共享初稿与反馈

共248,586条物理响应；重复条件不等于独立题目。

分步回答的高分，可以用简洁表达保留下来

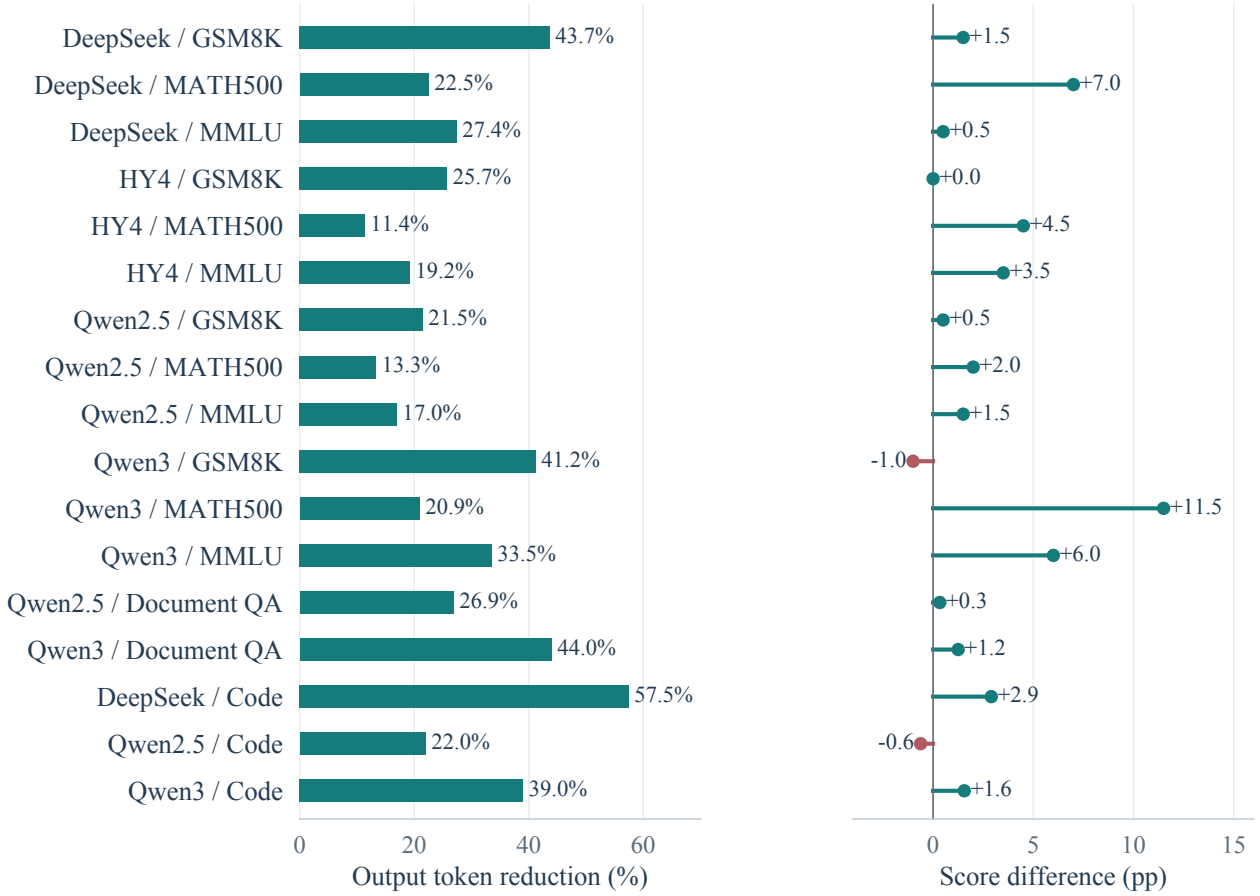


Qwen2.5 / GSM8K
分步后再要求简洁，
平均输出少21.5%，
得分91.5%→92.0%。

低维发现 1

来源：reports/baseline/reasoning_paired_contrasts.csv

简洁表达在三个任务方向反复出现

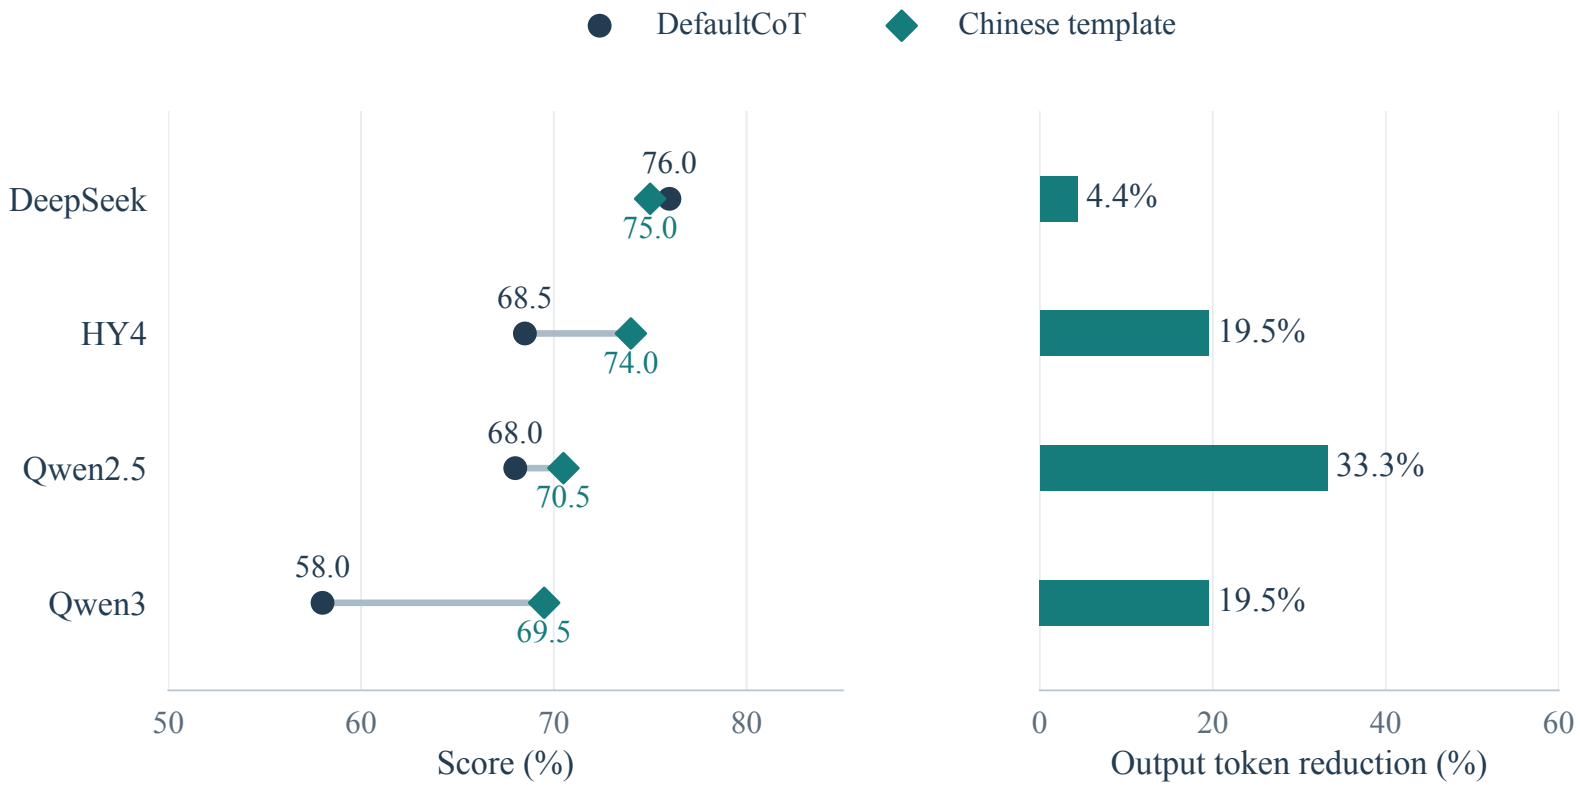


17/17 组缩短输出

15/17 组得分点估计持平或提高。推理、文档与代码按各自原评分对照。

不把三种评分合成一个准确率。

中文作答模板在 MATH500 上帮助多数模型省 Token、提分

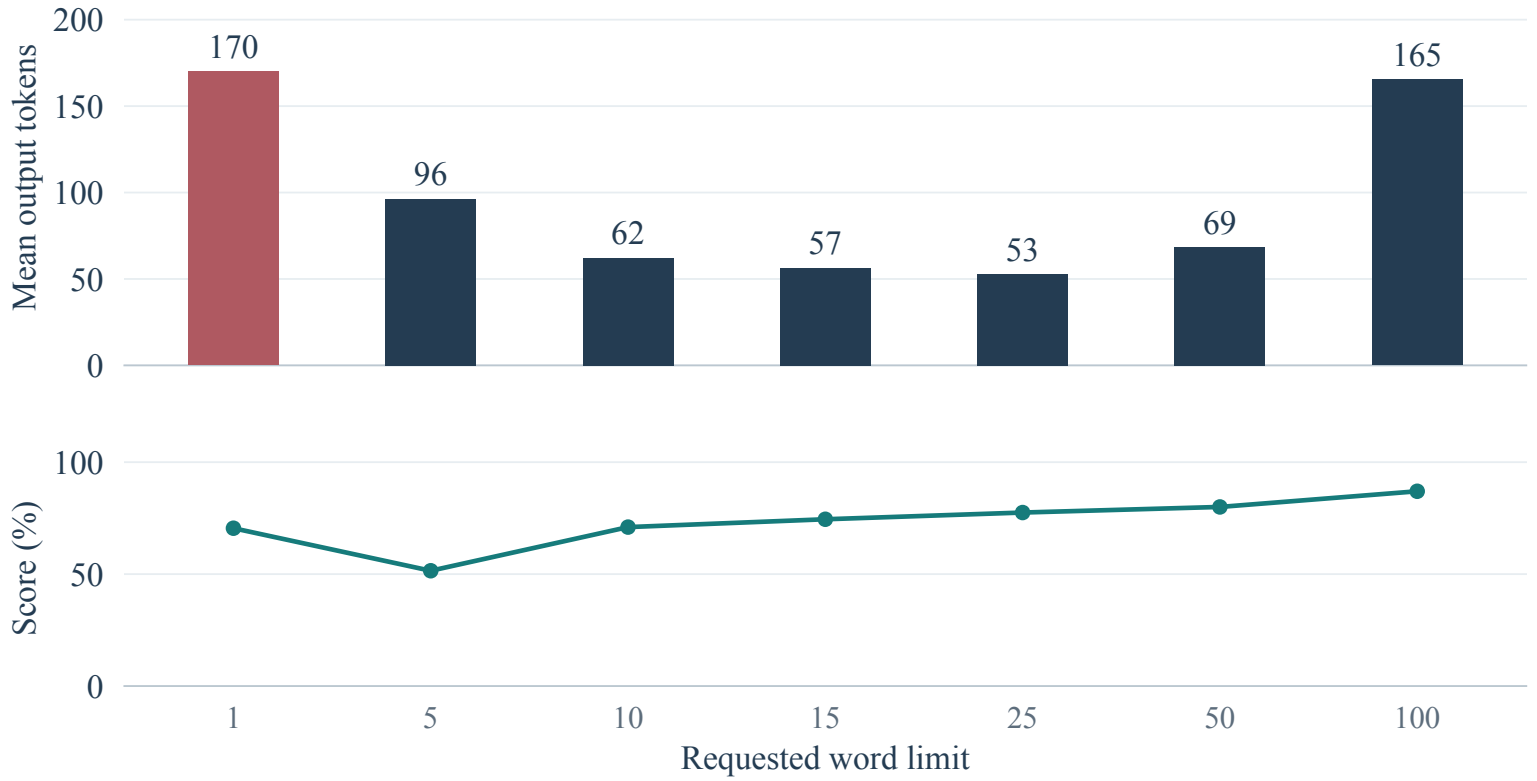


MATH500 四模型全部更短，三模型提分。Qwen3提高11.5 pp。

低维发现 2

来源：reports/story/chinese-template-comparison.csv

极端限长会引发输出反弹，格式处理挤占解题预算

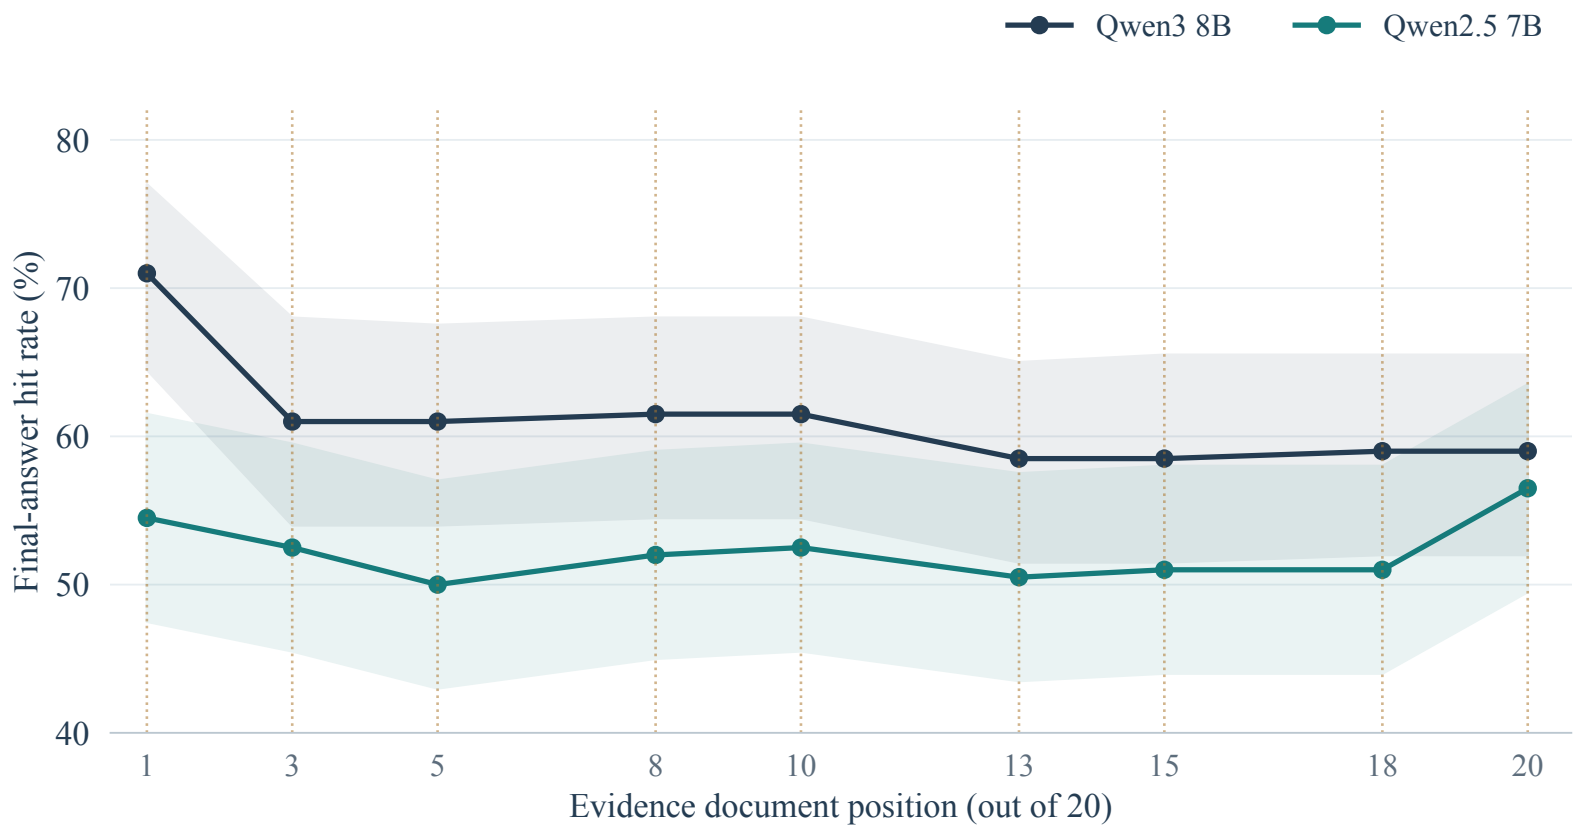


WordLimit 10→1 12 组中9组实际输出增加。提示限制不是接口硬上限。

异常 / 特殊现象

来源：reports/prompt_variants/reasoning-all-prompt-profiles.csv

证据位置会改变问答表现，也会改变模型差距



证据在首位→末位 两模型差距16.5 pp→2.5 pp。九点全部实测。

多维发现 1：模型 × 位置 → 命中

来源：reports/document_positions/position-summary.csv

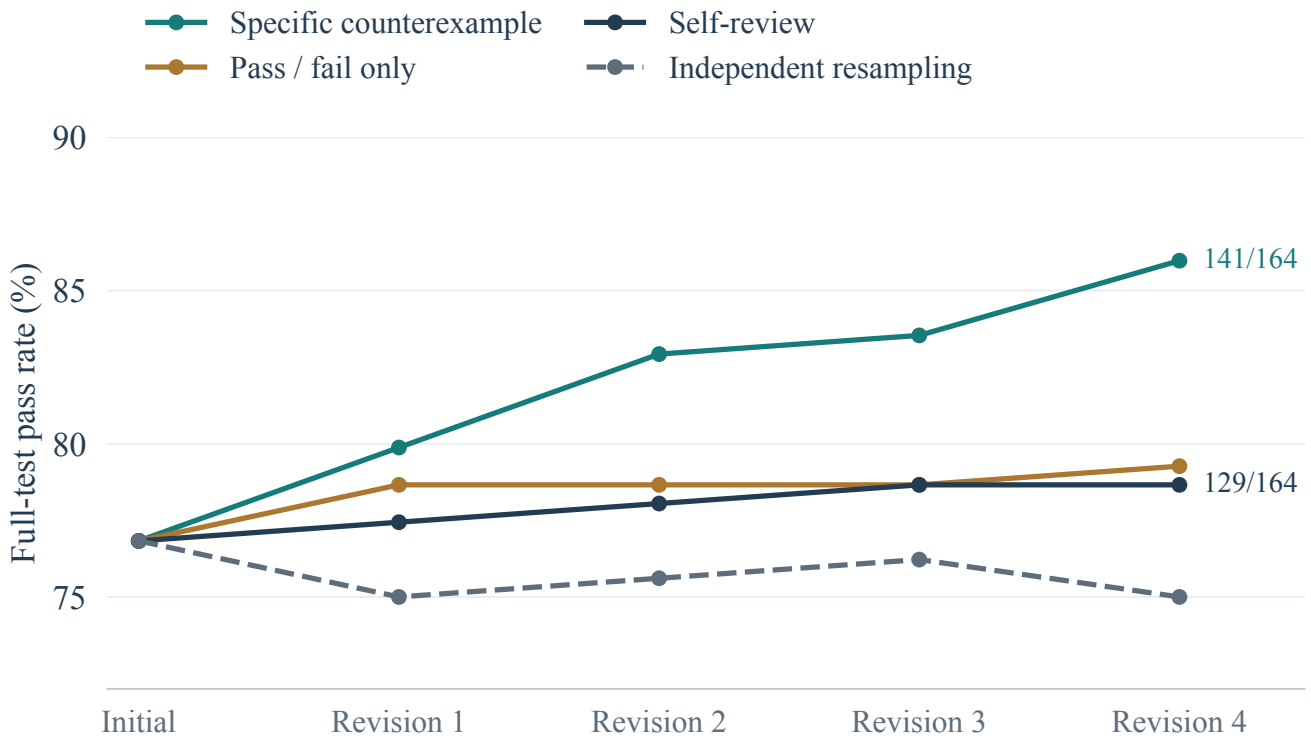
模型优势取决于证据出现在哪里

第1篇	第10篇	第20篇
16.5 pp	9.0 pp	2.5 pp

首尾模型增益差14.0 pp，配对95%区间 [5.5, 23.0]。

同题配对，比较“模型×证据位置”的联合关系。

具体执行反例比笼统检查更能推动多轮代码修复



Qwen3 第四轮 具体反例141/164；自行检查129/164。

多维发现 2：反馈 × 修改轮次 → 通过率

来源：reports/code_repair/full/curves.csv

区分独立采样与收到反馈后的修复

五次独立生成

模型看不到上一次回答，也不知道测试结果。DeepSeek Pass@1 30.22% → Pass@5 34.97%。

共享初稿 + 四轮反馈

后续回答携带历史程序与实际反馈。比较当前版本通过率，观察错误是否被修复。

Prompt可同时影响逻辑正确性与完整可执行代码的交付。

一个仓库，完整的数据到图表流程

冻结原始

405个源制品原字节保留

规范清洗

唯一键、类型、缺失与来源

配对分析

保留任务评分与重复结构

图稿与系统

SVG、五章与完整图表库

标准库启动网页；匿名特征可以复算全部条件汇总。

完整原始项目与课程匿名提交目录分别生成，后者按PDF目录树交付。

五条发现，形成一条完整故事

保留分步解题，压缩冗余表达。

中文模板帮助多数模型完成较难数学题。

过度限长可能反弹，更多约束不总是更省。

模型升级的收益，取决于证据的位置。

具体执行反例，让代码修复更有方向。

全部结论均有保存统计与真实实测点；模板、评分和环境范围在报告中说明。