模型行为研究：输出、资料与反馈

本项目通过推理/选择题、文档问答和 Python 代码实验，研究输出组织与任务结果的关系。以当前五条主发现形成“分步解题—简洁表达—语言模板—极端约束—证据位置—具体反馈”的故事。完整项目保存原始数据与代码；课程提交目录按匿名特征版本单独生成。

实验方向	物理回答	主要条件
推理提示	74,400	600题 / 四模型 / 31提示
文档问答	74,800	200题 / 文档数、位置与提示
代码生成	90,210	194题 / 三模型 / 31提示 / 五次独立采样
文档位置	3,600	复用200题 / 两模型 / 文档位置
代码修复	5,576	164题 / 两模型 / 共享初稿与四种处理

总计248,586条物理响应。不同任务的成功指标、重复条件和题目单位分别解释，不计算跨任务总准确率。

数据管道与匿名化

冻结源文件 → 唯一键与类型解析 → 源评分/执行结果连接 → 统一数值特征 → 同题配对分析 → 科学图稿与交互视图。原始输入405个不可变制品的SHA-256与整理前一致。源码、原始数据、清洗数据、统计和图稿分别存放，过程不覆盖原始文件。

CSV空单元格表示null，布尔true/false，时间统一UTC；未记录的耗时或Token不补0。

代码生成465条环境排除保留但不进入性能分母；89,745条回答可评，来自193道共同题。

修复初稿只记一次，pilot是全量批次的子集；共享初稿对应的逻辑组视图不增加API调用计数。

匿名提交版只携带数值特征、代码、统计和图稿；完整原题、回答、代码与源ID映射留在完整项目。

材料	位置
原始校验	data/inventory/raw_files.json
统一匿名表	data/processed/all_records.csv.gz
字段与缺失	data/data_dictionary.md；data/quality/missingness.csv
按阶段复算	scripts/pipeline.py；scripts/reproduce_anonymous.py

发现1：分步回答的高分，可以用简洁表达保留下来

低维发现 1。先比较只给答案的 NoCoT 与分步作答的 DefaultCoT，再在分步要求后追加 but be concise。固定 Qwen2.5/GSM8K 的 200 道同题，得分为 22.0%、91.5%、92.0%，平均输出为 6.5、236.7、185.8 Token。分步对照的配对得分差为 +69.5 pp，[63.0, 76.0]。

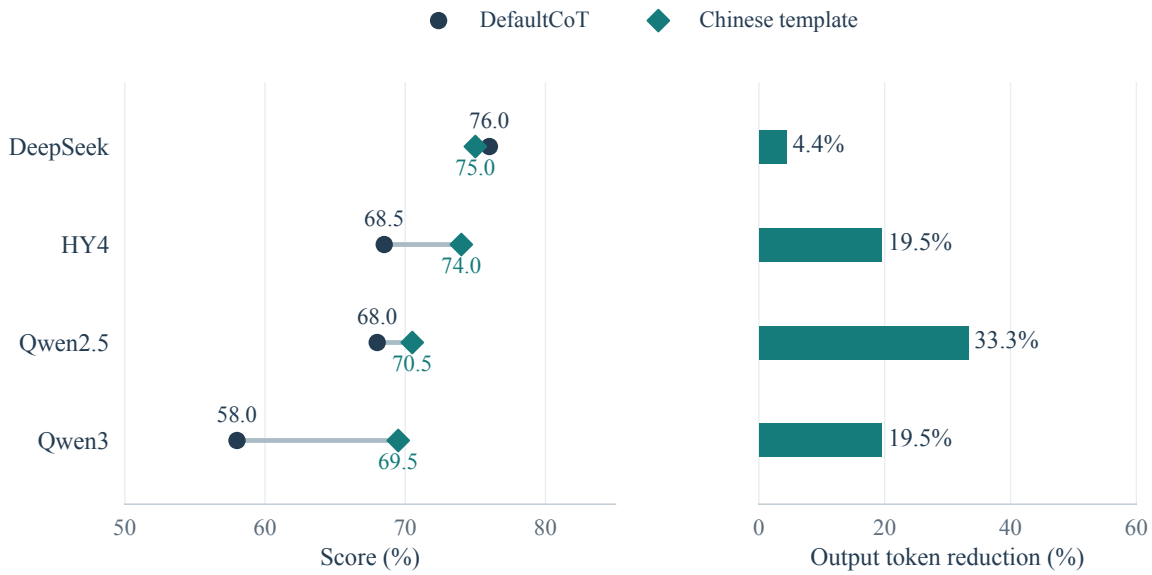


数据来源：reports/baseline/reasoning_paired_contrasts.csv；reports/story/concise-cross-task-points.csv

17 个模型×任务分组的简洁回答全部缩短，15 组得分点估计持平或提高，输出下降 11.4%–57.5%。默认表述中存在可压缩的复述和铺陈；两种得分相近不能单独证明统计等效。文档与代码任务按各自评分解释。

发现2：中文作答模板在 MATH500 上帮助多数模型省 Token、提分

低维发现 2。相同英文题，比较 DefaultCoT 与实际指令为 Respond in Chinese 的中文模板。MATH500 上，DeepSeek 76.0%→75.0%，HY4 68.5%→74.0%，Qwen2.5 68.0%→70.5%，Qwen3 58.0%→69.5%。四模型全部缩短输出，三模型提分。

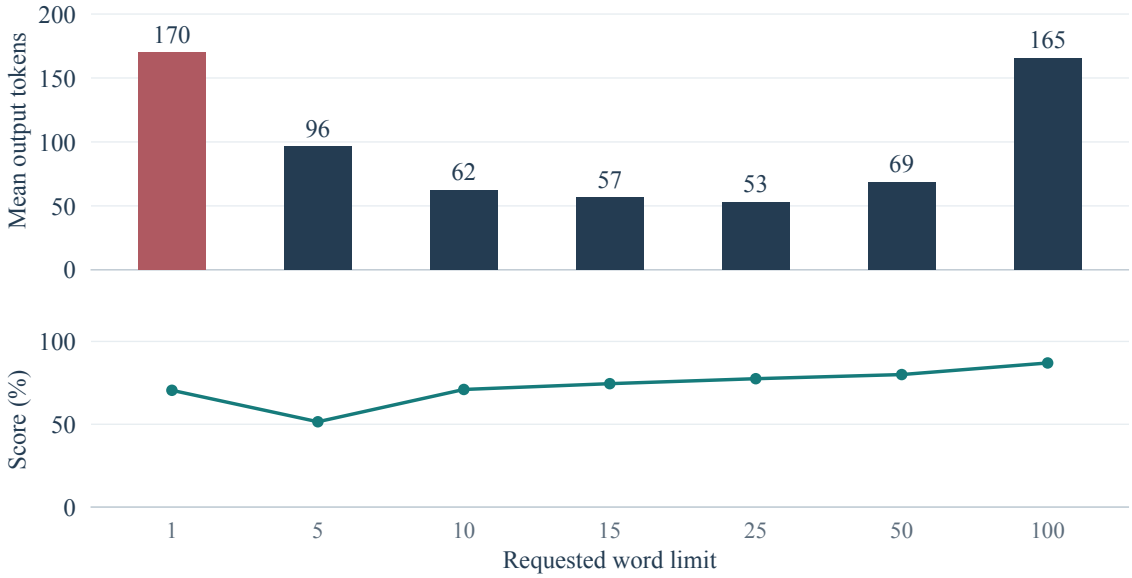


数据来源：reports/story/chinese-template-comparison.csv

Qwen3 提高 11.5 pp，输出减少 19.5%；Qwen2.5 截断率从 22.0% 降至 2.5%。得分改善的题中，原回答被截断的比例为 HY4 20/21、Qwen2.5 13/19、Qwen3 18/30。紧凑表达与完成情况改善共同解释这一现象。提分主张定位于 MATH500；GSM8K 四模型下降 0.5–4.5 pp。这是模板对照，不等同于只改变内部思考语言。

发现3：极端限长会引发输出反弹，格式处理挤占解题预算

异常 / 特殊现象。把词数上限从 10 压到 1，12 个模型×benchmark 分组中有 9 组平均输出增加。字母数 100→10 也有 9/12 组输出增加。DeepSeek/MATH500 的字母限制从 100→10 时，平均 Token 102.0→520.6，得分 83.5%→38.0%。

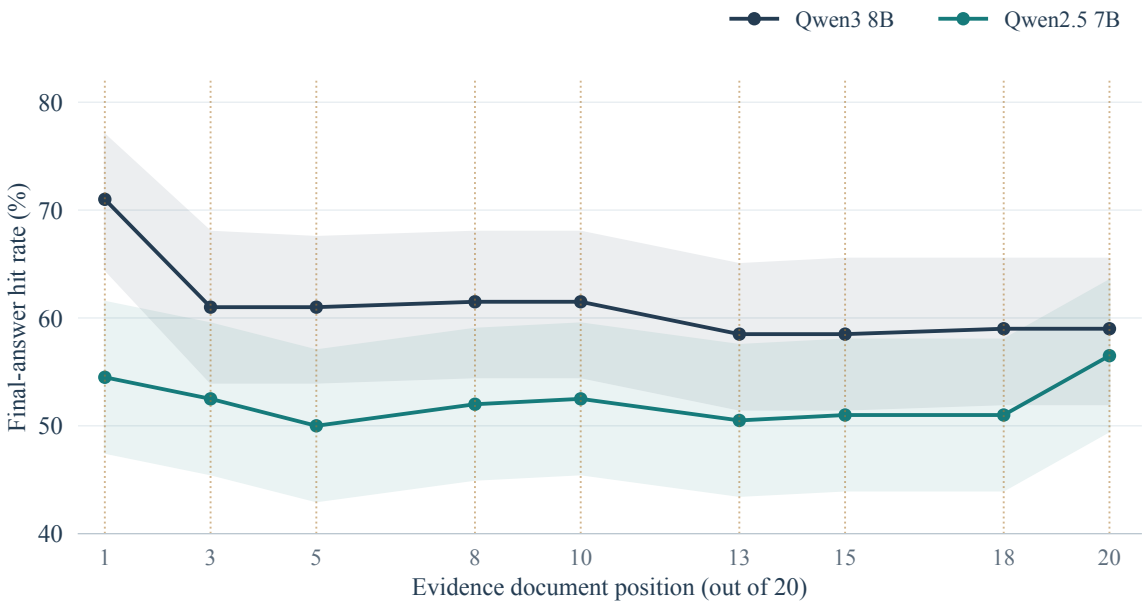


数据来源：reports/prompt_variants/reasoning-all-prompt-profiles.csv

同题因数案例中，100 字母条件用 25 Token 结束；10 字母条件已经算出答案，仍反复处理如何满足字母格式，最终在 801 Token 截断。温和简洁和极端限长产生了不同结果。主图每档均为实测，横轴是离散提示档位，未生成额外采样点；词数、字母数和接口 Token 也不是同一单位。

发现4：证据位置会改变问答表现，也会改变模型差距

多维发现 1：模型 × 位置 → 命中。固定 NoCoT、20 篇相同资料、200 道相同问题，仅移动相关文档。两模型、文档位置共 3,600 条回答。第1/10/20位：Qwen2.5 为 54.5%/52.5%/56.5%；Qwen3 为 71.0%/61.5%/59.0%。

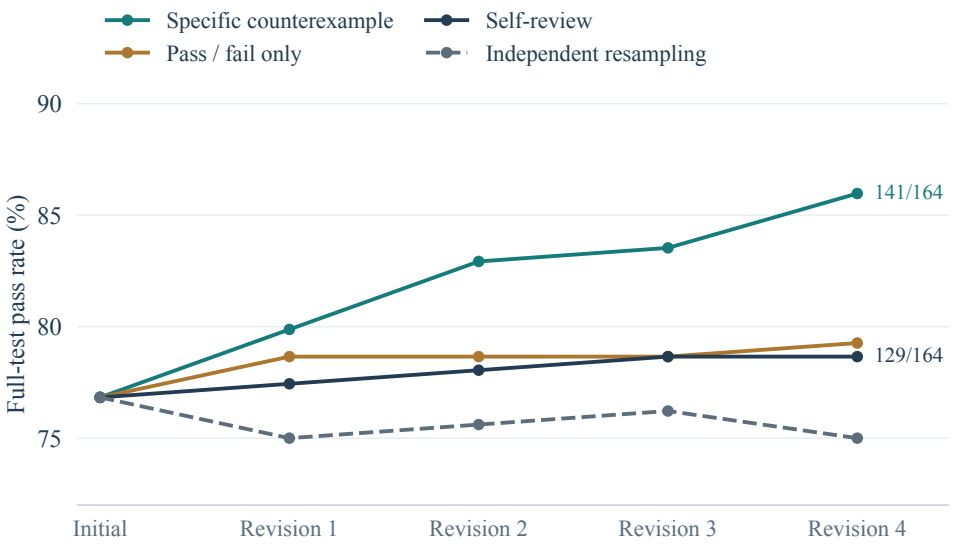


数据来源：reports/document_positions/position-summary.csv；paired-model-position-contrasts.csv

模型增益从首位 16.5 pp 缩至尾位 2.5 pp，首尾增益差 14.0 pp，配对区间 [5.5, 23.0]。Qwen2.5 呈浅 U 形轮廓，Qwen3 更突出首位优势；不强行给两条曲线套同一种形状。阴影为各位置命中率的95%区间。Qwen2.5 有 78/200 道题在文档位置间至少改变一次命中状态。文档问答提示实验与新文档位置批次分别保存。

发现5：具体执行反例比笼统检查更能推动多轮代码修复

多维发现 2：反馈 × 修改轮次 → 通过率。HumanEval+ Mini 164 题、两个 Qwen，每个模型×题目共享同一个初稿。四组分别是独立重采样、自行检查、仅通过/失败、具体失败输入与预期/实际结果。初稿后最多四轮；后三组保留历史，保留集测试结果不进入反馈。



数据来源：reports/code_repair/full/curves.csv；contrasts.csv

Qwen3 初稿 126/164；第四轮具体反例组 141/164，自检 129/164，差 +7.32 pp，[3.05, 12.20]。Qwen2.5 的对应差值 +1.83 pp。Qwen3 初始诊断测试失败的 30 题中，最终自检修复3题、仅状态4题、具体反例15题。图示当前版本完整测试通过率，不是把历轮成功累计在一起；5,576 条物理响应不重复累计共享初稿。

代码生成补充：独立采样与提示适配

CodePromptEval原始221题，经过参考实现检查和题意审查保留194题。每题×31提示×三模型独立生成五次。DeepSeek、Qwen2.5、Qwen3 的 Pass@1 分别为30.22%、22.59%、22.09%，Pass@5为34.97%、27.34%、28.01%。增加独立采样有覆盖收益，第4、5次的边际收益已较低。

模型	Pass@1	Pass@3	Pass@5
DeepSeek	30.22%	33.73%	34.97%
Qwen2.5	22.59%	26.04%	27.34%
Qwen3	22.09%	26.36%	28.01%

提示策略不仅影响代码逻辑，也影响完整可执行代码的交付。Qwen3的NoCoT提取失败较多；极端数字/语法格式会破坏函数交付。完整重新评分需要源CodePromptEval的项目依赖环境，本项目日常离线复算直接读取已保存的target-function-ast-v2结果。

数据来源：data/raw/code_generation/source_scores/；reports/code_generation/。

可视交互系统与课程对应

系统首页以五条发现、主图与结果解释组织。简洁作答提供同题与跨任务切换；语言和长度对照可选模型/题库；资料位置可选择九个位置与区间；代码修复可逐轮播放。完整图表库保留行为时间线、状态与错误类型、恢复路径、散点与热力、分组箱线和平行坐标等图。

课程要求	实现
两条低维	固定Qwen2.5/GSM8K的策略—得分；固定Qwen3/MATH500的模板—得分
两条多维	模型×证据位置→命中率；反馈×修改轮次→通过率
异常或局限	极端限长的输出反弹与截断；原评分、模板混合变化等边界
至少三个交互视图与联动	五章条件切换，完整图表库及筛选/记录联动
可运行交付	标准库启动、全部本地依赖、匿名特征复算、可编辑SVG

解释范围、复算与反思

数据支持的是当前模型、任务、提示和评测环境下的实测关系。我们不把接口输出当成已测得的内部思考过程，不把提示中的词数/Token数当成接口硬上限，也不把来源不同的分数合并解释。位置采集跨日期，模型ID相同不保证服务权重相同；代码测试通过也不保证所有输入都正确。

完整项目：python scripts/pipeline.py all --plan 查看阶段；snapshot只构建系统，不访问模型。

匿名复算：python scripts/reproduce_anonymous.py 从248,586行数值特征重算全部条件汇总；加--figures重绘主图。

图表全部有坐标、单位、真实实测点和来源；英文图字为Times New Roman。没有以插值假造更多证据位置。

AI辅助范围为代码整理、清洗统计、可视化及表达；源响应和已保存评分不由本轮重写，未伪造人工语义复核。

参考材料：课程题目二PDF；Compressed-CoT提示策略；Lost in the Middle 文档位置协议；CodePromptEval源提交9dfc592；HumanEval+ Mini v0.1.10。来源与SHA-256随各实验元信息保存。