《数据分析与可视化实践》课程设计题目二

AI 对话数据与智能体行为分析

一、课程设计基本信息

- 总分：100 分
- 完成形式：小组项目，4～5 人
- 主要工具：Python、ECharts、D3.js、Plotly、Vega-Lite 等

二、课程设计目标

学生通过自行采集与 AI 的对话数据或智能体运行日志，完成从数据获取、清洗、分析到可视化表达的完整流程，达到以下目标：

- 掌握对话数据或智能体日志的采集、匿名化和伦理规范。
- 掌握 JSON/CSV 等格式日志的读取、解析和结构化方法。
- 能够根据研究问题设计数据采集方案，选择合适的分析维度。
- 能够根据数据特点选择恰当的可视化形式，展示行为序列、模式、关系和差异。
- 能够使用 Python 可视化库，或 ECharts、D3.js 等前端图表库，制作静态或交互式图表。
- 能够依据分析结果形成有证据支持的结论，讲述数据故事或构建可探索系统。
- 理解行为分析的局限性，区分描述性发现与因果解释。

三、数据来源与采集要求

1. 数据来源

自行采集与 AI 的对话数据或智能体运行日志，可选来源包括（不限于）：

- 自己与 ChatGPT、Claude、Gemini、文心一言、通义千问等通用 AI 的对话记录；
- 自己运行编码智能体产生的日志；
- 自己搭建的简单智能体的运行记录。

2. 任务设置

至少设计 2～3 个不同任务，例如：数据读取与统计、文件处理、图表生成、网页信息提取、生成或调试 Python 代码等。
总消息数不少于 150 条，或总对话轮次不少于 100 轮。
鼓励使用同一任务对比不同 AI 模型或不同提示策略。

3. 研究方向参考

可根据兴趣选择以下方向之一，也可自主提出方向：

场景 A：通用对话行为分析

研究问题示例：在完成任务的过程中，AI 主要采用了哪些交互模式？对话轮次与任务完成质量之间有什么关系？
建议采集：完整对话文本、任务编号、运行编号、轮次编号、模型名称、响应时间。
可分析指标：对话轮次、交互模式占比、任务完成率、用户纠正次数。
可视化方向：行为时间线、交互模式分布图、任务对比箱线图。

场景 B：提示词策略对比

研究问题示例：零样本、少样本、思维链提示下，AI 回复质量有何差异？不同提示词策略下，代码一次通过率是否不同?
建议采集：提示词编号和策略类型、提示词全文、模型完整回复、执行结果、模型参数。
可分析指标：首次通过率、澄清次数、平均轮次、回复长度、错误率。
可视化方向：分组柱状图、平行坐标图、提示词策略对比热力图。

场景 C：多模型对比

研究问题示例：不同模型在相同任务下的代码正确率有何差异？哪个模型的错误修复效率更高?
建议采集：模型名称和版本、统一任务说明、每次运行的完整日志、代码、执行结果、错误信息、响应时间、Token 消耗。
可分析指标：错误发生率、首次修复成功率、平均修复轮次、工具调用次数、响应时间。
可视化方向：分组箱线图、散点图、雷达图、模型对比热力图。

场景 D：AI Coding 与错误修复效率

研究问题示例：当代码执行返回错误时，智能体如何响应？是重试、修改参数、切换策略，还是终止？不同错误类型的修复成功率如何?
建议采集：结构化运行日志、生成的代码片段、执行结果和错误信息、修复尝试和修复轮次、最终任务状态、工具调用记录。
可分析指标：错误率、修复成功率、平均修复轮次、工具调用效率、循环调试次数。
可视化方向：错误恢复路径图、交互树、行为时间线、工具调用与完成度散点图。

场景 E：自定义方向

学生可自主提出研究问题，但必须在报告中说明：研究问题是什么、需要哪些数据、计划记录哪些字段、哪些字段无法获取及如何处理、预期分析方法和可视化形式。

4. 采集提示

- 尽量提前明确研究问题，有目标的采集数据。
- 原始数据不可覆盖：采集后立即备份，后续清洗在副本上进行。
- 尽量全的记录采集环境：模型版本、温度、系统提示、任务说明。
- 统一任务：同一场景下使用相同任务，便于横向比较。
- 及时标注：采集后尽快补充任务编号、运行编号等元信息，避免遗忘。
- 匿名化：去除姓名、学号、API Key、邮箱等个人身份信息。
- 数据字典：每个字段说明含义、来源、缺失原因。
- 区分原始与派生：交互模式分类、错误标记等在分析阶段生成，不在采集时填写。
- 记录失败案例：错误、异常、循环调试往往是最有价值的分析对象。

5. 记录字段参考

不强制统一字段，应根据研究问题自主决定记录哪些字段，并在数据字典中说明每个字段的来源、含义和缺失原因。以下为常见字段参考：

字段	说明	适用场景
timestamp	时间戳	所有
task_id	任务编号	所有
run_id	运行编号	所有
turn_id	对话轮次	所有
role	角色：user / agent / assistant / tool	所有
content	文本内容	所有
model	模型名称及版本	所有
prompt_id	提示词编号	提示词对比
prompt_variant	提示词策略类型	提示词对比
prompt_text	提示词全文	提示词对比
response_time	响应时间（秒）	模型对比、效率分析
token_usage	输入/输出 Token 数	模型对比
tool_call	工具名称或 null	API/智能体日志
tool_input	工具输入或 null	API/智能体日志
tool_output	工具输出或 null	API/智能体日志
error	错误信息或 null	AI Coding、错误修复
result	成功 / 失败 / 进行中	所有
code_snippet	生成的代码	AI Coding
execution_result	执行结果	AI Coding
error_type	错误类型	AI Coding
fix_attempt	是否尝试修复	AI Coding
fix_round	修复轮次	AI Coding
final_status	最终状态	AI Coding

> 说明：若使用网页版对话且无法自动记录某些字段，可选择基础字段，并在数据字典中说明。交互模式分类、错误标记等属于分析阶段的派生字段，不要求在采集时填写。

6. 伦理与匿名化要求

- 采集前需获得参与者知情同意（如涉及他人对话）。
- 去除姓名、学号、API Key、电话号码、邮箱等个人身份信息。
- 不公开原始对话内容，只提交匿名化后的数据特征、数据分析结果和代码。
- 遵守 AI 平台的用户条款和数据使用政策。

四、分析建议与路径参考（非强制）

以下内容为分析路径建议，帮助开展探索。可根据自己的数据源和研究问题灵活选择，不要求逐项完成。最终考核以第五至第八部分的提交成果为准。

建议一：明确研究问题

可从以下角度提出 3～5 个具体问题：

- 在完成任务的过程中，AI 主要采用了哪些交互模式？例如：直接给出答案、分步推理、请求用户澄清、生成并执行代码、调用外部工具等。各类模式占比如何?
- 当 AI 的回答或代码未能满足要求时，用户如何提示纠正？AI 如何调整？是否重复同类错误?
- 不同任务类型下，AI 的对话轮次和任务完成质量有何差异?
- 不同 AI 模型或不同提示策略下，AI 的交互模式有何不同?
- 哪些任务容易引发重复错误或循环调试?

建议二：数据整合

- 将不同任务、不同运行的数据合并为统一结构；
- 补充任务类型、模型名称、运行编号等元信息；
- 建立数据字典，说明字段来源和缺失原因。

建议三：数据清洗与匿名化

- 检查字段名称和数据类型；
- 统一时间格式和角色命名；
- 处理重复记录；
- 统计缺失数量及比例；
- 识别并去除个人身份信息；
- 说明删除、填补或保留缺失值的依据。

建议四：分类与指标计算

根据研究问题和数据特点，定义分析维度或行为类别，并说明分类依据。类别数量和名称不作硬性规定。
可采用规则、关键词或 LLM API 辅助分类。
根据数据源选择计算指标，例如：对话轮次、交互模式占比、错误率、重试率、任务完成率、错误恢复平均轮次等。
若数据含工具调用记录，可统计工具调用总次数及各类占比；若为纯对话数据，可统计用户纠正次数、AI 澄清次数、代码生成次数等替代指标。

建议五：探索性分析

- 数据总体规模和结构说明；
- 交互模式或行为类别的描述性统计；
- 不同任务的行为分布比较；
- 错误与恢复路径分析；
- 不同模型或提示策略的行为差异分析。
  分析不应停留在“最多、最少、上升、下降”等简单描述，应结合任务背景、行为序列和指标关系进行解释。

五、产出要求（二选一）

选项 A：数据故事海报

要求：图文结合，讲述一个关于 AI 对话或智能体行为的数据故事。
必须包含：

- 研究问题：明确要回答的行为问题。
- 数据来源：说明采集方式、任务类型、样本量、匿名化处理。
- 分析维度：展示分类依据及编码方案。
- 自制图表：至少 4 幅有效图表，如行为时间线、交互模式分布图、错误恢复路径图、指标关系散点图等。
- 故事线：背景 → 问题 → 数据 → 发现 → 启示。
- 洞察：至少 5 条有数据支撑的结论（分类要求见第七部分）。
- 局限与反思：说明样本量、分类主观性、平台差异等限制。
- 分析代码：提交生成海报图表和统计结果的分析代码，确保可复现。
- 提交形式：海报 PDF/PNG（建议 A2 或 A1 比例），附分析说明文档和分析代码。

选项 B：可视交互系统

要求：构建一个支持数据探索与洞察的可视交互系统。
必须包含：

- 一个明确的分析目标：如“比较不同任务下 AI 的错误恢复模式”。
- 数据管道：日志解析 → 行为分类 → 结构化数据。
- 至少 3 个核心交互视图，例如：
    - 行为时间线或交互树；
    - 交互模式分布或错误类型图；
    - 原始对话/日志详情面板。
- 交互联动：至少实现一种联动，如筛选、点击、悬停、详情联动。
- 案例洞察：用系统探索出一个具体发现，并写成短报告。
- 可运行交付：代码仓库 + README + 演示。
  提交形式：可运行系统、代码仓库、案例报告。

六、可视化要求

海报组至少制作 4 幅有效图表；系统组至少实现 3 个交互视图。可参考以下视图类型：

图表类型	用途	参考内容
时间线 / 序列图	展示行为顺序	对话轮次、工具调用、错误与重试
柱状图、饼图、堆叠图	展示行为占比	各类交互模式、错误类型或任务状态占比
路径图 / 树图	展示错误恢复	错误 → 重试 → 成功/失败路径
散点图 / 热力图	展示指标关系	工具调用次数与任务完成度
分组箱线图、平行坐标图	展示模型或任务差异	多模型、多任务的指标对比
详情面板	查看原始文本	对话内容、工具输入与输出

图表规范

- 有明确标题；
- 标注坐标轴名称和计量单位；
- 图例、颜色和字体清晰；
- 不使用无实际意义的 3D 图；
- 颜色能够区分类别或表达数值大小；
- 图表下方或报告中给出数据发现及其分析依据；
- 注明数据来源

七、分析结论要求

最终报告或海报至少给出 5 条分析发现，其中：

- 至少 2 条描述和解释 一维或二维数据属性模式，例如：
  - 单一交互模式的频率分布、任务完成率；
  - 两个变量之间的关系，如对话轮次与错误率、用户纠正次数与任务完成度。
- 至少 2 条描述和解释 三维或以上数据属性之间关系，例如：
  - 同时考虑任务类型、模型、对话轮次对任务完成率的影响；
  - 用颜色、大小、分面等编码三个以上变量，分析多变量交互模式。
- 至少 1 条讨论 异常运行、特殊现象或数据局限，例如：
  - 某次运行出现循环重试或异常终止；
  - 某个模型在特定任务上表现异常；
  - 样本量、分类主观性、平台差异等限制。
- 进一步研究方向可在“局限与反思”部分说明，不强制单独列为一条发现。
- 所有结论必须能够在统计结果或图表中找到依据。不能把相关性直接表述为因果关系。

八、提交成果（结构示例）

1. 海报组

```
学号_姓名_AI对话行为分析_海报/
├── README.md
├── poster/
│   └── poster.pdf
├── src/
│   └── analysis.py         # 生成海报图表和统计结果
├── data/
│   ├── raw/
│   ├── processed/
│   └── data_dictionary.md
├── report/
│   └── 分析说明.pdf
└── presentation/
    └── 答辩PPT.pdf
```

2. 系统组

```
学号_姓名_AI对话行为分析_系统/
├── README.md
├── app/
│   └── （可运行系统代码）
├── data/
│   ├── raw/
│   ├── processed/
│   └── data_dictionary.md
├── report/
│   └── 案例报告.pdf
└── presentation/
    └── 答辩PPT.pdf
```

3. 通用要求

- README 给出代码运行说明，数据和代码可以运行复现提交的可视化图表；
- 代码路径使用相对路径；
- 原始数据如过大，可提供下载说明；
- 5～6分钟汇报视频，分辨率1080P，画面清晰，音画同步；
- PPT建议8～12页；
- 重点展示研究问题、关键图表、主要发现和项目反思。

九、评分标准

选项 A：数据故事海报评分表

评分项目	分值	具体评分要求
研究问题与选题	8	问题具体、可通过数据回答、有一定自主探索性
数据采集与伦理	8	采集方式规范、匿名化充分、引用完整
数据清洗与分类	15	清洗合理、分类清晰、依据充分
指标计算与分析	15	指标定义正确、统计合理、解释到位
可视化质量	20	图表类型恰当、信息准确、标注完整、配色协调
洞察与叙事	15	故事线清晰、结论有数据依据、不夸大因果
分析代码与可复现性	5	提交生成海报图表和统计结果的分析代码；可完整运行；路径规范；关键步骤可追溯
报告与海报规范	9	结构完整、图文对应、格式统一、引用规范
答辩表现	5	时间控制合理、表达清晰、能准确回答问题
合计	100	

选项 B：可视交互系统评分表

评分项目	分值	具体评分要求
研究问题与选题	8	问题具体、系统目标明确、有探索价值
数据采集与伦理	8	采集方式规范、匿名化充分、引用完整
数据清洗与分类	15	清洗合理、分类清晰、数据管道完整
指标计算与分析	15	指标定义正确、统计合理、解释到位
可视化质量	15	视图设计合理、信息准确、标注完整
系统功能与交互	20	视图可交互、联动有效、系统可运行
洞察与案例	9	能利用系统发现具体行为模式并解释
代码与可复现性	5	代码结构清晰、README 完整、可复现
文档与答辩	5	报告规范、演示清晰、能解释技术选择
合计	100	

十、评分等级说明

优秀：90～100 分

- 数据采集规范、匿名化充分、可复现；
- 研究问题有深度；
- 分析维度合理，指标计算准确；
- 图表美观、有效且具有较强叙事性或交互性；
- 结论充分，能主动讨论局限和反常现象。

良好：80～89 分

- 完成全部核心任务；
- 数据处理和指标计算基本正确；
- 图表规范，结论有数据支持；
- 分析具有一定深度，但自主探索或综合解释稍弱。

中等：70～79 分

- 完成大部分任务；
- 存在少量数据处理或可视化问题；
- 分析以描述性统计为主；
- 结论基本正确，但缺乏深入解释。

及格：60～69 分

- 基本完成数据采集、简单清洗和图表制作；
- 核心任务存在遗漏；
- 图表或结论较为简单；

- 分析代码或系统能够部分运行，但规范性不足。

不及格：60 分以下

- 未完成主要分析任务；
- 数据来源不明或数据处理严重错误；
- 多数图表无法正确表达数据；
- 分析代码或系统无法运行；
- 报告内容与代码、数据明显不一致。

十一、扣分与学术诚信规定

出现以下情况，可在对应项目之外追加扣分：

- 未注明数据来源：扣 5～10 分；
- 未提交原始数据或采集说明：扣 3 分；
- 未进行匿名化处理：扣 5～10 分；
- 图表缺少标题、单位或图例：每幅扣 1 分；
- 结论与图表明显不符：每处扣 2～5 分；
- 大量代码与他人高度雷同：按学校学术诚信规定处理；
- 伪造数据、篡改结果或直接提交他人成果：课程设计成绩记零。
- 允许合理使用生成式人工智能辅助解释代码、排查错误或优化表达，但学生必须说明使用范围，并能够在答辩中解释所有提交的代码和结论。